

UNIVERSIDAD PERUANA UNIÓN

FACULTAD DE INGENIERÍA Y ARQUITECTURA

Escuela Profesional de Ingeniería de Sistemas



Una Institución Adventista

**Tendencias/Técnicas tecnológicas para predicciones de evolución de precios
aplicados en el mercado de divisas (Forex)**

Por:

Junior Cercado Vásquez

David Melvin Requejo Santa Cruz

Morales, Septiembre del 2022

Introducción

El mercado de divisas, conocido como *Forex*, es el mercado financiero de intercambio de monedas más grande del mundo (Fisichella & Garolla, 2021) con una facturación diaria que se evalúa en más de 6 billones de dólares (Ni et al., 2019). Este es un mercado descentralizado que opera las 24 horas del día, excepto los fines de semana (Yıldırım, Toroslu, & Fiore, 2021); su tiempo de negociación se divide en zona australiana, asiática, europea y norteamericana, cada una con sus horarios de apertura y cierre (Islam et al., 2020). *Forex* es operado por bancos, instituciones financieras y comerciantes individuales o *traders* (Munkhdalai et al., 2019a). En él se negocian diferentes monedas (divisas) de distintos países (Pornwattanavichai, Maneeroj, & Boonsiri, 2022) y es pieza fundamental de la economía mundial. Los inversores se benefician de la compra o venta de monedas, también conocido como par de divisas (Dash et al., 2022).

Realizar operaciones de compra y venta en *Forex* implica enfrentar altos riesgos como aprovechar oportunidades de grandes beneficios para los *traders*, (Yıldırım, Toroslu, & Fiore, 2021). De hecho como lo afirman (Jarusek, Volna, & Kotyrba, 2022a), el riesgo y las oportunidades de estos negocios se deben a la concurrencia de factores económicos, políticos y psicológicos altamente correlacionados que interactúan de manera compleja.

En ese sentido, según (Pongsena et al., 2021) para que los *traders* tomen decisiones de compra y/o venta, constantemente buscan, analizan y utilizan herramientas que les ayuden a maximizar su rentabilidad y minimizar el riesgo; ya sea mediante análisis fundamental o análisis técnico. Así, el análisis fundamental basa en las noticias de *Forex* para predecir la tendencia del mercado como la tasa de inflación, la tasa de interés, el crecimiento económico, etc. (Pongsena et al., 2021); y, como apoyo del análisis técnico correcto es importante la identificación de patrones gráficos repetitivos del comportamiento del mercado.

Con mayor detalle, el análisis técnico gira en torno a la identificación de un conjunto de patrones gráficos predefinidos, y entre los más comunes encontramos banderas, banderines, hombro cabeza hombro, doble y triple piso (Hadizadeh Moghaddam & Momtazi, 2021). Según (Yong, Lee, & Ngo, 2020), esto se puede utilizar para pronosticar las fluctuaciones de precios según las reglas de inferencia comúnmente aceptadas y adoptadas por los *traders*.

Al respecto, (Hadizadeh Moghaddam & Momtazi, 2021) sostienen que la utilización de patrones gráficos de la evolución de los precios del mercado es la forma más fácil de analizar su proyección; por su parte (Yong et al., 2020) mencionan que todavía tienen inconvenientes debido a las propiedades de distorsión del tiempo de los patrones de gráficos y la dependencia de una gran cantidad de patrones de gráficos predefinidos. Por lo tanto, urge la necesidad de buscar soluciones que ayuden a entender este comportamiento para proporcionar información que ayude a tomar mejores decisiones a los *traders*.

El reconocimiento de patrones requiere un análisis deliberado de la experiencia del trading en lugar de un análisis numérico puro, este reconocimiento requiere que los comerciantes hagan juicios visuales sobre las imágenes; para (Ananthi & Vijayakumar, 2020) existen algunos algoritmos que son adecuados para el reconocimiento de imágenes.

Según (Hu, Zhao, & Khushi, 2021), utilizar métodos basados en el aprendizaje profundo para el modelado financiero está aumentando exponencialmente puesto que tiene mayor precisión y rendimiento en el campo de la predicción y el pronóstico financiero. Así, (Jing et al., 2019)

han logrado que su modelo obtenga una precisión del 98,8% en la identificación de patrones en Forex.

Por su parte (Carapuço, Neves, & Horta, 2018) utilizaron redes neuronales con tres capas ocultas de neuronas ReLU, a estos los entrenan como agentes RL bajo el algoritmo Q-learning, para lo cual utilizaron 8 años de datos del par de divisa EUR/USD de donde obtienen una ganancia total promedio de 16% anual del capital inicial.

En vista de lo anterior, nos planteamos como objetivo realizar una revisión sistemática de la literatura sobre las tendencias tecnológicas para predicciones de evolución de precios aplicados en el mercado de divisas Forex y conocer la efectividad de los mismos, teniendo en cuenta el análisis técnico sobre la tendencia de los precios en las divisas.

Materiales y métodos

Para lograr el objetivo planteado, aplicamos tres 03 fases metodológicas para la búsqueda y análisis de la literatura: Fase I. Elaboración de la pregunta de investigación; Fase II. Búsqueda de artículos científicos; y Fase III. Revisión, selección y análisis de estudios.

Fases de la búsqueda y análisis de la literatura.

1. Elaboración de la pregunta de investigación

- ¿ Que técnicas se utiliza para la predicción de evolución de precios aplicados *Forex*?
- ¿Qué técnicas de machine learning ofrecen mejores resultados en la predicción *Forex*?

2. Búsqueda de artículos científicos

Realizamos búsqueda de artículos a partir de la combinación de operadores booleanos y revisión de artículos científicos en bases de datos de Scopus, Web of Science (WOS) y SciELO.

Para los criterios de inclusión se consideró los artículos publicados entre los años 2018 y 2022, respectivamente, en idioma español, inglés.

3. Revisión y selección de estudios

Obtuvimos un total de 60 artículos. Los documentos tomados para esta revisión son artículos de revistas indexadas, los cuales importamos a Mendeley Desktop, para luego leerlos, y subrayarlos aplicando la técnica de paráfrasis para un mejor entendimiento.

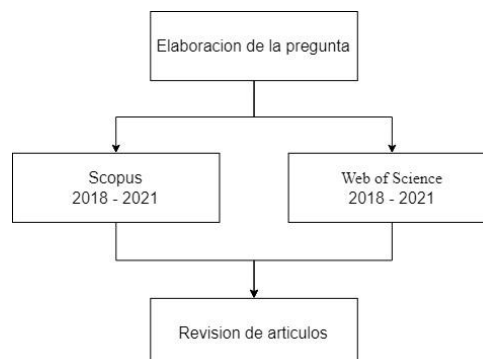


Fig. 1. Diagrama de selección de artículos.

Resultados y discusión

Técnicas clásicas de análisis técnico en el mercado de divisas.

Forex el mercado de divisas más grande del mundo, permite que *Traders* comercialicen tomando decisiones de compra o venta, muchas de las decisiones se basan en el análisis de patrones gráficos o velas como por ejemplo el patrón grafico bandera, banderines, hombro cabeza hombro, doble y triple piso de manera similar el patrón de velas envolventes alcistas o bajistas, a partir de este análisis técnico y en función a su experiencia los *Traders* deciden realizar una operación y posteriormente se estima la ganancia/perdida; para ello se toma en consideración el patrón grafico detectado en conjunto del patrón de velas, realizado el análisis y ejecutada la operación se fija un punto de pérdida (*stop loss*) y punto de ganancia (*take profit*), con el fin de detener la pérdida o cerrar con ganancias respectivamente.

En relación a lo anterior (Alanazi, 2020) menciona que si el patrón de vela envolvente es alcista y acompañado por uno de los patrones gráficos doble piso, triple piso, se ejecuta una operación de compra al precio de oferta abierta de la siguiente vela, de manera similar si el patrón gráfico detectado es doble techo, triple techo o hombro cabeza hombro apoyados con patrones de velas envolvente bajistas entramos en una operación de venta al precio de oferta abierta de la siguiente vela, en consecuente se fija el punto de perdida por debajo del mínimo anterior o si se ha comprado o por encima del máximo anterior si se ha vendido, así como se muestra en la figura 2.



Fig. 2. Par de divisa GBP/USD a las 7:30 UTC-5 del 21/10/2022 en una temporalidad de 30 minutos.

Por otro lado (Ramli et al., 2020) utilizaron el análisis técnico basado en el retroceso de Fibonacci en conjunto con ondas Eliot Wave. El análisis técnico Fibonacci son relaciones matemáticas, expresadas como proporciones, derivadas de las sucesiones de Fibonacci. Los principales índices de Fibonacci son 23,6%, 38,2%, 50% y 61,8%, estos índices se miden desde el inicio al final de un impulso donde el análisis Elliott wave nos ayuda a detectarlo. Elliott Wave está formada por 5 ondas (1, 2, 3, 4, 5) según la tendencia alcista o bajista, al final de la tendencia hay un retroceso de 3 ondas (A, B, C). El retroceso de Elliott wave tiene proporción

a los principales índices de Fibonacci. Las compra o ventas se toma al término del ciclo Elliott Wave en consideración de la tendencia alcista o bajista, así como lo muestra la figura 3 y 4.

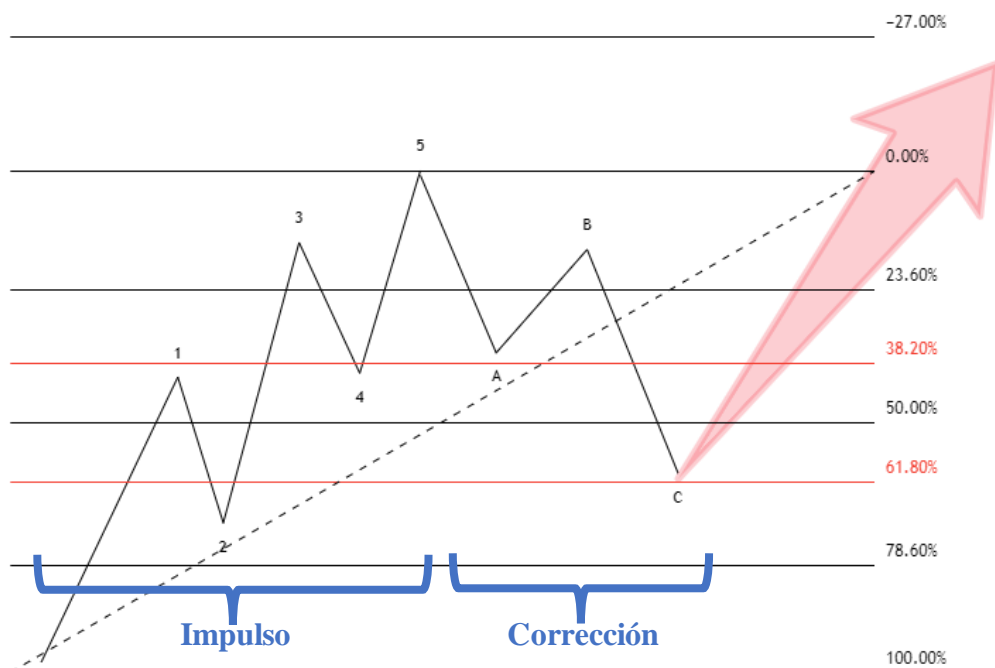


Fig. 3. Gráfico teórico de las ondas de Elliott en conjunto con el retroceso de Fibonacci



Fig. 4. Par de divisa GBP/USD a las 6:00 UTC-5 del 21/10/2022 en una temporalidad de 2 horas.

Las ventajas del uso de las herramientas tecnológicas en el mercado de divisas, y su influencia en el análisis técnico para una mejor toma de decisiones en el mercado Forex.

La predicción de *Forex* ha sido un interés clave para los *Traders* de todo el mundo. Se han aplicado numerosas tecnologías modernas además de modelos estadísticos a lo largo de los años (Durairaj & Mohan, 2022).

Ya existen muchas herramientas para ayudar a las *Traders* a predecir las fluctuaciones de los precios, (Chen & Tsai, 2020) menciona por ejemplo, las redes neuronales, el análisis de series temporales difusas, los algoritmos genéticos, los árboles de clasificación, los modelos de regresión estadística y las máquinas de vectores de soporte. Sin embargo, estos modelos de aprendizaje automático son técnicas genéricas y se utilizan para realizar pronósticos. Se combinan inusualmente con la experiencia financiera.

Arboles de decisión

Según (Chandrinou, Sakkas, & Lagaros, 2018) desarrollaron dos sistemas de gestión de riesgos AIRMS-DT y AIRMS-ANN utilizando árboles de decisión y neuronales artificiales respectivamente. Para entrenar el sistema, cubriendo un período de siete años (2010-2016) con los 5 principales pares de divisas (GBP/USD, USD/JPY, EUR/USD, GBP/JPY y EUR/JPY). Donde cada punto de entrada (compra o venta) anteriores alimentan AIRMS para clasificar las señales producidas de la estrategia comercial en: rentables y no. AIRMS basado en DT primero logró alcanzar un retorno total de cada una de las monedas incrementándola a una tasa promedio del 50%, de manera similar AIRMS basado en ANN logró aumentar el rendimiento total de las cinco monedas en un promedio del 40%. Concluyendo que este sistema no promete rendimientos más del 80% pero si nos da una cartera rentable a través del tiempo.

Red Neuronal Convolutiva

Los investigadores (Lee et al., 2019) tomaron imágenes de gráficos de velas japonesa de los índices bursátiles de EEUU como entrada para entrenar el modelo *convolutional neural network* (CNN), este modelo CNN está formado por 6 capas ocultas, las cuatro primeras capas ocultas son capas convolucionales y las dos últimas capas ocultas son capas FC. En las capas FC, la ReLU se implementa sólo después de la quinta capa. Con el modelo implementado lograron que las carteras construidas a partir de los resultados, arrojen entre un 0,1% y un 1,0% de rentabilidad por transacción. Los resultados mostraron que algunos patrones gráficos indican los mismos movimientos de los precios de las acciones en los mercados bursátiles mundiales, llegando a la conclusión que el modelo implementado no solo funciona para el mercado donde se realizó el entrenamiento, sino que también funciona bien o incluso mejor en muchos otros.

Por otro lado (Chen & Tsai, 2020) utilizaron el campo angular de Gramian (GAF), un nuevo método de codificación de series de tiempo, el cual permite representar datos de series de tiempo en un sistema de coordenadas y utilizar varias operaciones para convertir ángulos en matriz de simetría y las *convolutional neural network* (CNN), modelo que se utilizan ampliamente en problemas de reconocimiento de patrones e imágenes, como primer paso utilizaron la codificar la serie temporal como diferentes tipos de imágenes con el método GAF, y en segunda instancia utilizaron las CNN con las imágenes GAF para el reconocimiento de patrones de velas japonesas.

Para el entrenamiento de los modelos utilizaron datos de precios de 1 minuto EUR/USD desde el 1 de enero de 2010 hasta el 1 de enero de 2018, incluidos 1000 datos de entrenamiento, 200 datos de validación y 350 datos de prueba, tras el entrenamiento de los modelos concluyeron que el modelo GAF-CNN puede identificar los ocho tipos de patrones de velas japonesas con una precisión promedio del 90,7 % (Chen & Tsai, 2020).

Otra investigación realizada por (Hadizadeh Moghaddam & Momtazi, 2021) han propuesto un modelo que funciona conjuntamente con el patrón técnico de cruce de medias móviles. Para ello, han utilizado un modelo conjunto que se beneficia de dos tipos diferentes de técnicas de procesamiento inteligente, el procesamiento de imágenes que se aplica a las velas japonesas obtenidas del historial de precios y el análisis de series temporales que se aplica a las propiedades numéricas. Para el primer proceso, utilizaron la Red Neural Convolutiva (CNN) y para el último proceso, CNN con Memoria a Largo Corto Plazo (LSTM) para la predicción. Para el modelo propuesto se aplicaron datos del par EUR/USD. Las pruebas se realizaron para valores de dispersión de 0.5, 1, 1.5 y 2. Los investigadores lograron mostrar que el modelo híbrido logra resultados superiores en comparación con los patrones de análisis técnico del Índice de Fuerza Relativa (RSI) y Bandas de Bollinger (BB) individuales.

En cuanto a los investigadores (Durairaj & Mohan, 2022) presentaron un nuevo modelo híbrido, Caos+CNN+PR, este está formado por la teoría del caos, la red neuronal convolutiva (CNN) y la regresión polinómica (PR) respectivamente, primero comprobaron si las series temporales financieras son confusas usando la Teoría del Caos, luego a las series temporales obtenidas se introdujeron en la CNN para obtener predicciones iniciales, posteriormente, con las series de errores obtenidas a partir de las predicciones de la CNN fueron ajustadas por PR para obtener predicciones de error, finalmente sumaron las predicciones de error y las predicciones iniciales de la CNN logrando obtener las predicciones finales. Para el entrenamiento utilizaron tipos de cambio de la Reserva Federal: rupias indias (INR) / USD, yen japonés (JPY) / USD, dólar de Singapur (SGD) / USD, índices bursátiles, Standard & Poor (S&P)500, Nifty 50 y Shanghai y precios de productos básicos en dólares estadounidenses, el precio del petróleo crudo, el precio del oro y el precio de la soja, los datos se dividen en un conjunto de entrenamiento (80%) y un conjunto de prueba (20%) de observaciones, tras el entrenamiento y las pruebas los investigadores llegaron a la conclusión que el híbrido propuesto es superior a las medias móviles integradas autorregresivas (ARIMA), Prophet, Classification and Regression Tree (CART), Random Forest (RF), CNN.

Los autores (Jing et al., 2019) utilizaron el aprendizaje CNN profundo para predecir la dirección del cambio en los tipos de cambio EUR/USD, GBP/USD, JPY/USD. El entrenamiento se desarrolló a partir de 1565 precios de cierre, extraídos de los años 2010 y 2015, logrando obtener un detector que permite identificar los límites de los patrones de análisis técnico de diversos tamaños en los gráficos de precios. Como resultado de la investigación lograron concluir que el detector tiene con una precisión que gira en torno al 98,6% con una velocidad de respuesta de la NN Convolutiva de aproximadamente 0,65 segundos por 1000 muestras de datos.

Red neuronal recurrente

Los investigadores () lograron implementar un sistema basado en redes neuronales recurrentes LSTM, el sistema emite señales de compra o venta, para que estos mencionan que el sistema permite predecir el movimiento del mercado con un nivel de precisión suficiente para que el usuario pueda decidir si una cotización de una acción es una 'Compra/Venta' y si debe venderla en corto o en largo. La precisión de predicción de la bolsa de valores se ha analizado y mejorado al 85% utilizando algoritmos de aprendizaje automático.

Los autores (Yıldırım et al., 2021) utilizaron LSTM, para crear un modelo híbrido llamado "LSTM macroeconómico" (ME-LSTM) y "LSTM técnico" (TI-LSTM) que permite predecir el cambio direccional en el par de divisas EUR/USD, este modelo se compone de dos modelos LSTM independientes que tienen diferentes configuraciones de sus parámetros y que permite como entrada diversos grupos de datos, para el aprendizaje de los modelos, los datos se dividieron en conjuntos de entrenamiento y prueba, con proporciones de 80% y 20%, respectivamente. Como resultado obtuvieron que el modelo híbrido tiene un desempeño en términos de beneficio_precisión para las predicciones en promedio 73,61 %, los autores mencionan que han demostrado que su modelo sea eficaz en muchos problemas de pronóstico de series temporales, para hacer predicciones de dirección en Forex.

K vecinos más próximos

Los autores (Ananthi & Vijayakumar, 2020) implementaron un sistema basado técnicas de algoritmo de aprendizaje automático, el algoritmo utiliza el método de regresión K vecinos más próximos (K-NN). Para obtener el conjunto de datos usan una biblioteca de código abierto llamada Quandl, esta biblioteca tiene datos financieros para ser analizados por el algoritmo K-NN, luego se predicen la tendencia del mercado basándose en otros indicadores como el MACD, el RSI, las bandas de Bollinger y también la detección de patrones de velas. Posteriormente a los análisis realizados se generan señales de compra o venta los cuales se muestran utilizando API Rest. Los autores concluyeron que la presión de este algoritmo oscila entre 75% y 95% según el conjunto de datos de entrenamiento y se retroceden según su distancia. Además, se menciona que, en el futuro, se implementará un análisis de sentimiento completo que ayude a lograr un mayor rendimiento en términos de predicción de tendencias del mercado teniendo en cuenta que el alcance de la predicción de tendencias del mercado es muy amplio.

Tabla 1

Estudios realizados con diferentes técnicas de predicción.

#	cita	Conjunto de datos	Periodo	Características	Método	Resultado
1	(Chen et al., 2018)	Datos de transacciones de alta frecuencia de futuros CSI300	2017	Datos de precios	DNN, ELM, RBF	Accuracy DNN = 0.7310 Accuracy ELM = 0.5060 Accuracy RBF = 0.5720
2	(Chandrinou et al., 2018)	GBP/USD, USD/JPY, EUR/USD, GBP/JPY y EUR/JPY	2010 - 2016	Datos de precios	ANN, DT	Incremento De 50% de la cartera.
3	(Carapuço et al., 2018)	EUR/USD	2010 - 2017	Datos de precios por ticks	Q-learning	Promedio anual de 16.3%
4	(Munkhdalai et al., 2019b)	EUR/USD, USD/JPY, USD/CHF, GBP/USD, USD/CAD y AUD/USD	2000 - 2019	Datos de precios	RNN, GRU, LSTM, MLP	RNN = 0.271875 GRU = 0.2225 LSTM = 0.17625 MLP = 0.20625
5	(Lee et al., 2019)	Russell 3000	2001 - 2018	Imágenes gráficas	de DQN, CNN	Incremento de 10% a 100% de la cartera.
6	(Das et al., 2019)	USD/INR, USD/EUR, SGD/INR, YEN/INR	2000 - 2016	Datos de precios	de ELM, OSELM, RBPNN	90% precisión de predicción.
7	(Dash, 2020)	USD/AUD, USD/GBP, USD/INR	2014 - 2015	Datos de precios	de RLPNN-ISFL	60% precisión de predicción.
8	(Chen & Tsai, 2020)	EUR/USD	2010 - 2018	Datos de precios	de CNN, GAF	90,7% precisión.
9	(Ahmed et al., 2020)	EUR/USD	2015 - 2018	Datos de precios	de LSTM	MSE = 10,96 %
10	(Alanazi, 2020)	Pares de divisa mayores y menores	2000 - 2018	Datos de precios	de Análisis técnico	Incremento de 14% de la cartera.
11	(Juszczuk & Kruś, 2020)	Pares de divisa mayores y menores	2010 - 2018	Datos de precios	de Enfoque nítido. Enfoque difuso multicriterio.	57% a 70% precisión de predicción.

12	(Yıldırım et al., 2021)	EUR/USD	2013 - 2018	Datos precios	de LSTM	73.61% de precisión en promedio.
13	(Hadizadeh Moghaddam & Momtazi, 2021)	EUR/USD	2020	Datos precios. Imágenes de gráficos.	de CNN, LSTM	71% de precisión.
14	(Shah et al., 2022)	Nifty 50	2011-2020	Datos precios	de CNN-LSTM	34.2% de rendimiento anual
15	(Jarusek, Volna, & Kotyrba, 2022b)	EUR/USD, USD/JPY, CHF/JPY y EUR/CHF.	2015-2018	Datos precios	de Onda de Elliott. Transformación rápida de Fourier. Redes neuronales artificiales.	50% a 72% precisión de predicción.
16	(Jing et al., 2019)	EUR/USD, JPY/USD	GBP/USD, 2010-2015	Datos precios	de CNN	98,6% precisión de predicción

En la tabla 1, Se realizó una revisión exhaustiva de las investigaciones, donde se encontró que los resultados obtenidos fueron favorables, oscilando entre el 10% y el 99%, así mismos pudimos determinar que los datos utilizados para el análisis están entre 1 año y 20 años y que la mayoría de ellos son precios de cotizaciones de divisas e índices.

Conclusiones

A partir de este estudio podemos afirmar que existen dos técnicas comunes que permiten predecir la evolución de los precios en el mercado *Forex*, el primero es una técnica manual que combina tres factores, la experiencia del *trader*, el análisis técnico y fundamental, el análisis técnico gira en torno a la identificación de un conjunto de patrones gráficos predefinidos, y el análisis fundamental se basa en noticias, tasa de inflación, la tasa de interés, el crecimiento económico, etc.

El segundo es una técnica automatizada basado en modelos de machine Learning tales como, CNN, RNN, LSTM, Q-LEARNING, ANN, DNN entre otros, estos utilizan los precios o imágenes de las divisas para su aprendizaje. Consecuentemente estas técnicas son utilizadas para predicciones de las divisas, sin embargo, los modelos de machine Learning prometen mejores resultados.

De acuerdo con los resultados anteriores, este estudio recomienda que los traders incluyan modelos de aprendizaje automático, siendo uno de ellos las redes neuronales convolucionales (CNN) que logran resultados superiores al 70%, del mismo modo los modelos híbridos ofrecen resultados superiores al 60%. Estos resultados son favorables para la toma de decisiones de compra/venta y en consecuencia el aumento de su cartera.

Referencias

- Ahmed, Salman, Saeed Ul Hassan, Naif Radi Aljohani, and Raheel Nawaz. 2020. "FLF-LSTM: A Novel Prediction System Using Forex Loss Function." *Applied Soft Computing Journal* 97:106780. doi: 10.1016/j.asoc.2020.106780.
- Alanazi, Ahmed S. 2020. "The Bullish and the Bearish Engulfing Patterns: Beating the Forex Market or Being Beaten?" *The European Journal of Finance* 26(15):1484–1505. doi: 10.1080/1351847X.2020.1748679.
- Ananthi, M., and K. Vijayakumar. 2020. "Stock Market Analysis Using Candlestick Regression and Market Trend Prediction (CKRM)." *Journal of Ambient Intelligence and Humanized Computing* 12(5):4819–26. doi: 10.1007/s12652-020-01892-5.
- Carapuço, João, Rui Neves, and Nuno Horta. 2018. "Reinforcement Learning Applied to Forex Trading." *Applied Soft Computing Journal* 73:783–94. doi: 10.1016/j.asoc.2018.09.017.
- Chandrinou, Spyros K., Georgios Sakkas, and Nikos D. Lagaros. 2018. "AIRMS: A Risk Management Tool Using Machine Learning." *Expert Systems with Applications* 105:34–48. doi: 10.1016/j.eswa.2018.03.044.
- Chen, Jun Hao, and Yun Cheng Tsai. 2020. "Encoding Candlesticks as Images for Pattern Classification Using Convolutional Neural Networks." *Financial Innovation* 6(1):26. doi: 10.1186/s40854-020-00187-0.
- Chen, Lin, Zhilin Qiao, Minggang Wang, Chao Wang, Ruijin Du, and Harry Eugene Stanley. 2018. "Which Artificial Intelligence Algorithm Better Predicts the Chinese Stock Market?" *IEEE Access* 6:48625–33. doi: 10.1109/ACCESS.2018.2859809.
- Das, Smruti Rekha, Kuhoo, Debahuti Mishra, and Minakhi Rout. 2019. "An Optimized Feature Reduction Based Currency Forecasting Model Exploring the Online Sequential Extreme Learning Machine and Krill Herd Strategies." *Physica A: Statistical Mechanics and Its Applications* 513:339–70. doi: 10.1016/j.physa.2018.09.021.
- Dash, Rajashree. 2020. "Performance Analysis of an Evolutionary Recurrent Legendre Polynomial Neural Network in Application to FOREX Prediction." *Journal of King Saud University - Computer and Information Sciences* 32(9):1000–1011. doi: 10.1016/j.jksuci.2017.12.010.
- Dash, Swaty, Pradip Kumar Sahu, Debahuti Mishra, Pradeep Kumar Mallick, Bharti Sharma, Mikhail Zymbler, and Sachin Kumar. 2022. "A Novel Algorithmic Forex Trade and Trend Analysis Framework Based on Deep Predictive Coding Network Optimized with Reptile Search Algorithm." *Axioms* 11(8):396. doi: 10.3390/axioms11080396.
- Durairaj, Dr. M., and B. H. Krishna Mohan. 2022. "A Convolutional Neural Network Based Approach to Financial Time Series Prediction." *Neural Computing and Applications* 34(16):13319–37. doi: 10.1007/s00521-022-07143-2.
- Fischella, Marco, and Filippo Garolla. 2021. "Can Deep Learning Improve Technical Analysis of Forex Data to Predict Future Price Movements?" *IEEE Access* 9:153083–101. doi: 10.1109/ACCESS.2021.3127570.
- Hadizadeh Moghaddam, Arya, and Saeedeh Momtazi. 2021. "Image Processing Meets Time

- Series Analysis: Predicting Forex Profitable Technical Pattern Positions.” *Applied Soft Computing* 108:107460. doi: 10.1016/j.asoc.2021.107460.
- Hu, Zexin, Yiqi Zhao, and Matloob Khushi. 2021. “A Survey of Forex and Stock Price Prediction Using Deep Learning.” *Applied System Innovation* 4(1):1–30.
- Islam, Md Saiful, Emam Hossain, Abdur Rahman, Mohammad Shahadat Hossain, and Karl Andersson. 2020. “A Review on Recent Advancements in FOREX Currency Prediction.” *Algorithms* 13(8):186. doi: 10.3390/a13080186.
- Jarusek, Robert, Eva Volna, and Martin Kotyrba. 2022a. “FOREX Rate Prediction Improved by Elliott Waves Patterns Based on Neural Networks.” *Neural Networks* 145:342–55. doi: 10.1016/j.neunet.2021.10.024.
- Jarusek, Robert, Eva Volna, and Martin Kotyrba. 2022b. “FOREX Rate Prediction Improved by Elliott Waves Patterns Based on Neural Networks.” *Neural Networks* 145:342–55. doi: 10.1016/j.neunet.2021.10.024.
- Jing, Liting, Zhi Li, Xiang Peng, Jiquan Li, and Shaofei Jiang. 2019. “A Relative Equilibrium Decision Approach for Concept Design Through Fuzzy Cooperative Game Theory.” *Journal of Computing and Information Science in Engineering* 19(4). doi: 10.1115/1.4042837.
- Juszczuk, Przemysław, and Lech Kruś. 2020. “Soft Multicriteria Computing Supporting Decisions on the Forex Market.” *Applied Soft Computing Journal* 96:106654. doi: 10.1016/j.asoc.2020.106654.
- Lee, Jinho, Raehyun Kim, Yookyung Koh, and Jaewoo Kang. 2019. “Global Stock Market Prediction Based on Stock Chart Images Using Deep Q-Network.” *IEEE Access* 7:167260–77. doi: 10.1109/ACCESS.2019.2953542.
- Munkhdalai, Lkhagvadorj, Tsendsuren Munkhdalai, Kwang Ho Park, Heon Gyu Lee, Meijing Li, and Keun Ho Ryu. 2019a. “Mixture of Activation Functions with Extended Min-Max Normalization for Forex Market Prediction.” *IEEE Access* 7:183680–91. doi: 10.1109/ACCESS.2019.2959789.
- Munkhdalai, Lkhagvadorj, Tsendsuren Munkhdalai, Kwang Ho Park, Heon Gyu Lee, Meijing Li, and Keun Ho Ryu. 2019b. “Mixture of Activation Functions With Extended Min-Max Normalization for Forex Market Prediction.” *IEEE Access* 7:183680–91. doi: 10.1109/ACCESS.2019.2959789.
- Ni, Lina, Yujie Li, Xiao Wang, Jinquan Zhang, Jiguo Yu, and Chengming Qi. 2019. “Forecasting of Forex Time Series Data Based on Deep Learning.” Pp. 647–52 in *Procedia Computer Science*. Vol. 147.
- Pongsena, Watthana, Prakaidoy Sitsayabut, Nittaya Kerdprasop, and Kittisak Kerdprasop. 2021. “Development of a Model for Predicting the Direction of Daily Price Changes in the Forex Market Using Long Short-Term Memory.” *International Journal of Machine Learning and Computing* 11(1):61–67. doi: 10.18178/ijmlc.2021.11.1.1015.
- Pornwattanavichai, Arisara, Saranya Maneeroj, and Somjai Boonsiri. 2022. “BERTFOREX: Cascading Model for Forex Market Forecasting Using Fundamental and Technical Indicator Data Based on BERT.” *IEEE Access* 10:23425–37. doi: 10.1109/ACCESS.2022.3152152.
- Ramli, Mohd Fauzi, Ahmad Kadri Junoh, Mahyun Ab Wahab, and Wan Zuki Azman Wan

- Muhamad. 2020. "Fibonacci Retracement Pattern Recognition for Forecasting Foreign Exchange Market." *International Journal of Business Intelligence and Data Mining* 17(2):159–78. doi: 10.1504/IJBIDM.2020.108775.
- Shah, Atharva, Maharshi Gor, Meet Sagar, and Manan Shah. 2022. "A Stock Market Trading Framework Based on Deep Learning Architectures." *Multimedia Tools and Applications* 81(10):14153–71. doi: 10.1007/s11042-022-12328-x.
- Yıldırım, Deniz Can, Ismail Hakkı Toroslu, and Ugo Fiore. 2021. "Forecasting Directional Movement of Forex Data Using LSTM with Technical and Macroeconomic Indicators." *Financial Innovation* 7(1):1. doi: 10.1186/s40854-020-00220-2.
- Yong, Yoke Leng, Yunli Lee, and David Chek Ling Ngo. 2020. "Adaptive Detection of FOREX Repetitive Chart Patterns." *Pattern Analysis and Applications* 23(3):1277–92. doi: 10.1007/s10044-019-00862-8.