

Mejora de la estimación de inversión de tendencia en los mercados de divisas bajo un paradigma de cambios direccionales con algoritmos de clasificación

Adesola Adegboye¹ | Michael Kampouridis² | fernando otero¹

¹Escuela de Informática, Universidad de Kent, Canterbury, Reino Unido

²Facultad de Informática y Ingeniería Electrónica, Universidad de Essex, Colchester, Reino Unido

Correspondencia
Michael Kampouridis, Facultad de Informática e Ingeniería Electrónica, Universidad de Essex, Wivenhoe Park, Colchester CO4 3SQ, Reino Unido.

Correo electrónico: mkampo@essex.ac.uk

Resumen

La mayoría de los métodos de pronóstico utilizan una escala de tiempo física para estudiar las fluctuaciones de precios de los mercados financieros. El uso de escalas de tiempo físicas puede hacer que las empresas no se den cuenta de actividades significativas en el mercado, ya que el flujo de tiempo es discontinuo, lo que podría traducirse en oportunidades rentables perdidas o exposición al riesgo. Los cambios direccionales (DC) han ganado atención en los últimos años al traducir series temporales físicas a series basadas en eventos. Bajo este marco, las inversiones de tendencia se pueden predecir utilizando la duración de los eventos.

Tener este conocimiento permite a los comerciantes tomar medidas antes de que ocurran tales reversiones y, por lo tanto, aumentar su rentabilidad. En este artículo, investigamos cómo se pueden incorporar algoritmos de clasificación en el proceso de predicción de reversiones de tendencias para crear estrategias comerciales basadas en DC. El efecto de la estimación de inversión de tendencia propuesta se mide en 20 mercados de divisas durante un período de 10 meses en un total de 1000 conjuntos de datos.

Comparamos nuestros resultados a través de 16 algoritmos, tanto basados en DC como no basados en DC, como análisis técnico y comprar y mantener. Nuestros hallazgos muestran que la introducción de la clasificación conduce a generar mayores ganancias y supera estadísticamente a todas las demás estrategias comerciales.

PALABRAS CLAVE

modelo de clasificación, cambios direccionales, datos forex, programación genética

1 | INTRODUCCIÓN

Pronosticar el comportamiento futuro de los instrumentos financieros es una actividad importante en los mercados financieros.¹ Una forma típica de estudiar series de precios es muestreando datos en una escala de tiempo física, por ejemplo, precios de cierre diarios, donde los precios se muestrean en intervalos diarios. Sin embargo, este enfoque tiene una desventaja: no tiene en cuenta los movimientos de precios potencialmente importantes que ocurren entre esos puntos fijos en el tiempo. Por ejemplo, si estuviéramos utilizando los precios de cierre diarios, no habríamos podido registrar el desplome repentino que ocurrió en los índices bursátiles de EE. UU. el 6 de mayo de 2010 desde las 2:32 p. m. hora del este (EDT) hasta las 3:08 p. m. EDT, ya que los precios se recuperaron poco después.

Una alternativa al muestreo de datos en intervalos de tiempo fijos es el llamado muestreo de datos de tiempo intrínseco. En este enfoque, los datos se muestrean según la observación de eventos significativos en el mercado.^{2–4} La razón es registrar eventos clave en el mercado que representen movimientos de precios significativos (por ejemplo, cambios de precios en un 2 %), que normalmente se pasarían por alto métodos tradicionales de tiempo físico. Se han documentado diferentes técnicas de muestreo de tiempo intrínseco, por ejemplo, puntos perceptuales importantes,^{5,6} punto de inflexión,⁷ zigzag,^{8,9} y más recientemente cambios direccionales (DC).^{10,11} Bajo el paradigma DC, un umbral γ es definido, que se utiliza para detectar cambios significativos en los precios. El mercado se resume entonces en tendencias alcistas y bajistas. Cada una de estas tendencias consta de un evento DC, que suele ir seguido de un evento de sobreimpulso (OS). El uso de diferentes valores de umbral permite la detección de diferentes eventos y, como consecuencia, la creación de diferentes resúmenes de tendencias. Por lo tanto, el marco DC se centra en el tamaño de un cambio de precio a medida que varía el tiempo, mientras que en el tiempo físico, el intervalo de tiempo es fijo (por ejemplo, los precios de cierre diarios).

Si bien la teoría detrás de DC nos dice que un evento DC generalmente es seguido por un evento OS, hemos encontrado a partir de resultados experimentales preliminares que puede existir una gran cantidad de casos en los que un evento DC no es seguido por un evento OS; en cambio, es seguido por un evento DC en la dirección opuesta.¹² Como resultado, podemos tener conjuntos de datos con un número extremadamente bajo de eventos DC con un evento OS correspondiente, incluso tan bajo como 14.77%; este es, por supuesto, el umbral γ dependiente. Por lo tanto, no se puede suponer que cada evento DC será seguido por un evento OS correspondiente.

En este estudio, estamos interesados en investigar esto más a fondo mediante la introducción de un paso de clasificación, que predice si un evento DC será seguido por un evento OS. Tener este conocimiento nos permitirá tener una mejor comprensión de la dinámica del mercado y aumentar la capacidad de rentabilidad comercial. Para validar esto, aplicamos un paso de clasificación a tres algoritmos comerciales diferentes basados en CD e informamos cómo se ve afectado el rendimiento comercial. Nuestro objetivo es demostrar que la introducción del paso de clasificación puede mejorar significativamente la rentabilidad de las estrategias comerciales basadas en CD y también superar otras estrategias comerciales no basadas en CD, como el análisis técnico y comprar y mantener. Para lograr esto, llevamos a cabo experimentos rigurosos utilizando datos de 20 pares de divisas de Forex en 1000 conjuntos de datos diferentes; lo que hace que nuestros resultados sean robustos y generalizables.

El resto de este documento está organizado de la siguiente manera. La Sección 2 presenta un resumen de los cambios de dirección y la literatura relevante. La Sección 3 presenta nuestra metodología, detallando cómo incorporamos algoritmos de clasificación en la predicción de si ocurre o no un evento OS. La Sección 4 presenta la configuración de nuestros experimentos, mientras que la Sección 5 presenta nuestros resultados y análisis. Finalmente, la Sección 6 concluye este artículo y discute el trabajo futuro.

2 | CAMBIOS DE DIRECCIÓN

2.1 | Visión general

Un evento de DC se identifica mediante cambios de precio definidos por un valor de umbral especificado por el usuario. Los eventos de DC se dividen en eventos de subida y bajada. Una vez que se confirma un evento DC, generalmente sigue un evento OS; un evento OS finaliza una vez que se confirma un evento DC en la dirección opuesta. Una tendencia de DC, hacia arriba o hacia abajo, consiste en la combinación de un evento de DC y OS. Diferentes umbrales generan diferentes series de eventos. Los umbrales más pequeños crean una mayor cantidad de eventos de DC que los umbrales más grandes, que producen menos eventos.

Veamos ahora la Figura 1, donde presentamos cómo podemos resumir una serie de precios de tiempo físico en eventos de DC y OS. En este ejemplo, resumimos los movimientos de precios con dos umbrales diferentes, a saber, $\tilde{y} = 0,01\%$ (líneas en rojo) y $\tilde{y} = 0,018\%$ (líneas en azul).




FIGURA 1 Cambios direccionales para el par de divisas GBP/JPY FX. Las líneas rojas representan eventos creados por un umbral $\tilde{y} = 0,01\%$ y las líneas azules eventos creados por un umbral $\tilde{y} = 0,018\%$. Los eventos de DC se indican con líneas sólidas y los eventos del sistema operativo con líneas discontinuas. Bajo $\tilde{y} = 0,01\%$, resumimos los datos de la siguiente manera: Evento de recesión DC: Punto AB \tilde{y} ; Evento OS hacia abajo: Punto B \tilde{y} C; Evento Upturn DC: Punto C \tilde{y} D; Evento OS ascendente: Punto DE \tilde{y} ; Evento de recesión DC: Punto E \tilde{y} F. Bajo $\tilde{y} = 0,018\%$, resumimos los datos de la siguiente manera: Recesión; Evento OS hacia abajo: Punto DE \tilde{y} ; Evento Upturn DC: Punto C \tilde{y} E; Punto EE \tilde{y} A, C, E y E \tilde{y} . Puntos de confirmación DC: Puntos A, B, C, D, E y F. Puntos de cambio de dirección: OS, rebasamiento

Los cambios de precio por debajo de \tilde{y} no se consideran un evento significativo. Los cambios de precios por encima de \tilde{y} se consideran eventos significativos y dividen el mercado en tendencias alcistas y bajistas. Las líneas sólidas representan eventos de DC y las líneas discontinuas representan eventos del sistema operativo. Por ejemplo, bajo $\tilde{y} = 0.01\%$, entre los Puntos A y B tenemos un evento DC descendente seguido de un evento OS descendente desde el Punto B al C; cuando se produce un cambio de tendencia, un evento de DC ascendente comienza desde el Punto C al D. Por último, entre el Punto D y el E es un evento OS ascendente. El punto de precio donde comienza o termina una tendencia DC se llama punto extremo DC (DCE); bajo $\tilde{y} = 0.01\%$, los puntos A, C y E son puntos extremos de CC.

Bajo $\tilde{y} = 0.018\%$ (líneas en azul), obtenemos un conjunto diferente de eventos: de A a B \tilde{y} : un evento de recesión; de B \tilde{y} a C: un OS hacia abajo; de C a E: un evento DC de recuperación; por último, del punto E al E \tilde{y} tenemos una tendencia OS ascendente.

Tenga en cuenta que solo podemos confirmar un evento DC en retrospectiva, es decir, después de que haya habido un cambio de precio de \tilde{y} . Por ejemplo, bajo $\tilde{y} = 0.01\%$ no sabríamos que estamos en una tendencia ascendente hasta que hayamos alcanzado el punto D. Este punto se llama punto de confirmación DC (DCC). Antes del Punto D, uno consideraría que el mercado ha tenido una tendencia a la baja desde el Punto A. De manera similar, no sabríamos que la tendencia se ha invertido de arriba a abajo hasta que hayamos alcanzado el Punto DCC F. Por lo tanto, es crucial poder para predecir con precisión cuándo se producirá un cambio de tendencia.

DC ha ofrecido a los comerciantes nuevas perspectivas sobre los movimientos de precios y ha dado lugar a nuevas direcciones de investigación, que no eran posibles con los resúmenes de precios en tiempo físico. En la siguiente sección, presentamos brevemente algunos de los trabajos recientes de DC.

2.2 | Revisión de la literatura reciente de DC

De acuerdo con la referencia [13], las leyes de escala se refieren a hallazgos empíricos aceptados como verdaderos debido a su consistencia. 14 fue el primer trabajo que derivó leyes de escala utilizando cambios direccionales. Desde entonces, varios otros trabajos han descubierto nuevas leyes de escala. Algunos ejemplos son Referencia [15] que descubrió 17 nuevas leyes de escala; Referencia [10], que descubrió 12 leyes adicionales; Referencia [16], que agregó cuatro leyes de escala más; y Referencia [17], que además contribuyó con cinco leyes de escala. Además, la Referencia [11] presentó cuatro nuevos indicadores de CD para perfilar los mercados financieros. Desde entonces, se han introducido 18 más indicadores de CD y se han utilizado para la creación de perfiles. 19, 20 Otro cuerpo de trabajo de CD se ha centrado en estimar la inversión de tendencias y el comercio. Por ejemplo, las Referencias [16, 21] combinaron el cambio direccional con el seguimiento de tendencias y los indicadores técnicos comerciales contrarios, y desarrollaron nuevas estrategias comerciales. Además, Referencia [22, 23] creó una estrategia comercial basada en DC, llamada "DBA", e informó rendimientos medios de alrededor del 14%. Los cambios direccionales también se han combinado con algoritmos de aprendizaje automático, por ejemplo, un sistema neuro-borroso; Referencia [24] programación genética; Referencia [25] y árboles de decisión; Referencia [26] pero también con modelos econométricos, como un FyGARCH. 27

2.3 | Relaciones de duración de eventos de DC y OS

Una de las leyes de escala más interesantes es la que describe la relación entre la duración (duración) de los eventos de DC y OS. Más específicamente, la Referencia [10] encontró evidencia empírica de que la duración de un evento OS es en promedio el doble de la duración de su correspondiente

Evento DC (Ecuación 1). Dichas leyes se pueden aprovechar para los comerciantes y tomar acciones comerciales antes se alcanza el final de una tendencia. Se hicieron observaciones empíricas similares en Referencias [28,29]. Sin embargo, propusieron una formulación más genérica, donde la relación de longitud de DC y OS se expresó como una función lineal con una constante M , donde M es la duración promedio del evento DC relación de longitud de evento a OS para los conjuntos de datos dados (Ecuación 2). Por último, la Referencia [12] presentó un algoritmo de programación genética (GP), que llevó a cabo una tarea de regresión simbólica y evolucionó fórmulas lineales y no lineales (Ecuación 3). El uso de un método de cabecera permitió buscar la mejor función que describe la relación de longitud de DC y OS, sin necesidad de hacer suposiciones sobre la forma de esta relación.

$$OS = 2 \times DC \quad (1)$$

$$OS = M \times DC \quad (2)$$

$$SO f CC II = () \quad (3)$$

Como mencionamos anteriormente, es posible que no todos los eventos de DC tengan un SO correspondiente evento; en su lugar, podría seguir otro DC de la dirección opuesta. Observaciones empíricas en La referencia [12] mostró que podría haber conjuntos de datos con tan solo un 14,77 % de eventos de DC con un evento del sistema operativo correspondiente. Esta es una observación importante, porque indica que las ecuaciones (1)–(3) son significativos solo en aquellos casos en los que un DC va seguido de un OS. Usemos un ejemplo para aclarar este tema. Supongamos que un evento de DC ascendente dura 2 días y luego es seguido directamente por un evento de DC descendente que dura 4 días. Si intentamos aplicar cualquier de las ecuaciones anteriores, digamos la Ecuación (1), estaríamos prediciendo que el primer evento DC sería ser seguido por un evento OS, de la misma dirección, que terminaría 4 días después (ya que $OS = 2 \times DC$). Un comerciante con la expectativa anterior podría esperar hasta el final del cuarto día del evento OS para realizar una acción de venta, donde se espera que el precio esté en su punto más alto. Sin embargo, como en este caso ya ha habido un cambio de dirección, el comerciante terminaría vendiendo a un precio mucho más bajo, ya que estamos en una tendencia a la baja. En otras palabras, $OS = 2 \times DC$ es una aproximación de longitud de OS que no se cumple para todos los eventos de DC.

Para evitar estos problemas, proponemos introducir un paso de clasificación antes de la predicción de la inversión de tendencia mediante las Ecuaciones (1)–(3). Durante este paso, estaremos prediciendo si un El evento DC será seguido por un evento OS correspondiente. Solo cuando hay un sistema operativo correspondiente evento, aplicaremos las ecuaciones de inversión de tendencia anteriores.

3 | METODOLOGÍA

Nuestro objetivo es poder identificar los casos en los que un evento DC es seguido por un evento OS. Conseguir esto, vamos a introducir un paso de clasificación binaria. El primer valor de clase será que un DC es seguido de un evento del sistema operativo (lo llamamos $\check{y}DC$), y el segundo valor de clase será que el DC es no seguido por un evento OS (lo llamamos $\check{y}DC$). Cuando el clasificador predice $\check{y}DC$, aplicamos Ecuaciones (1)–(3) para estimar la relación entre las longitudes de DC y OS para predecir la tendencia punto de inversión (es decir, final del evento OS). Por otro lado, cuando el clasificador predice $\check{y}DC$, el punto de inversión de la tendencia se estimará como el final del evento DC. Este proceso se resume en la Figura 2: para evaluar su rentabilidad, incorporamos el paso de clasificación como parte de un estrategia comercial.

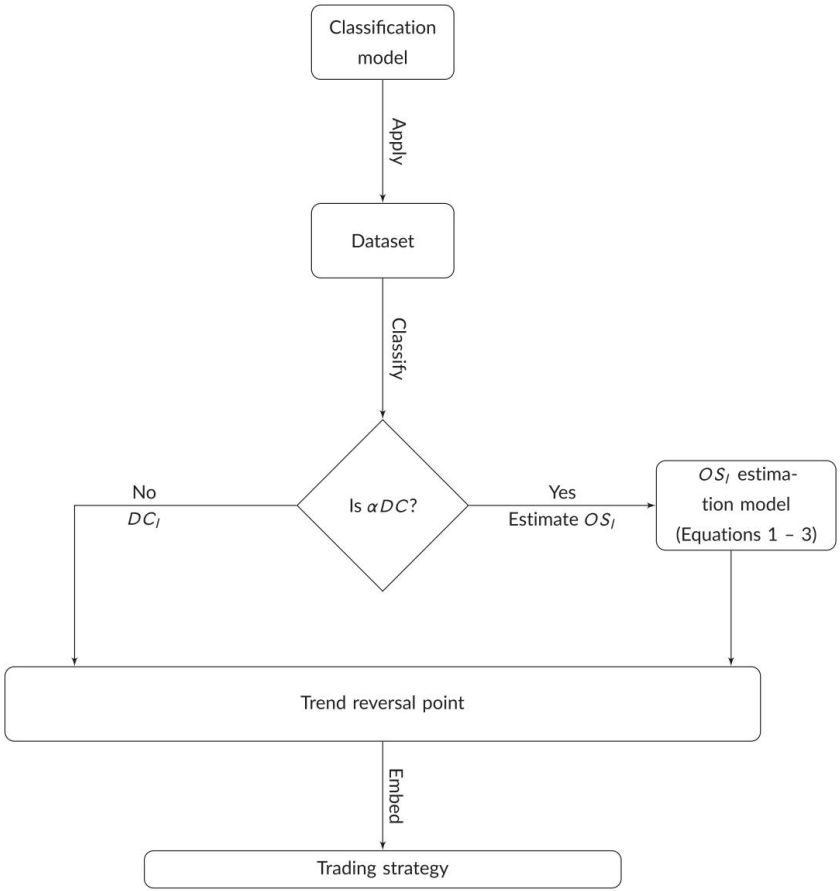


FIGURA 2 Estimación de inversión de tendencia propuesta bajo cambios direccionales. Cuando se predice que una tendencia DC será seguida por un evento OS, entonces se invertirá en DCE, que se calcula mediante la suma de las longitudes de los eventos DC y OS; la longitud del OS se estima mediante una de las Ecuaciones (1)–(3). Cuando se pronostica que una tendencia DC no tendrá un evento OS correspondiente, el punto de inversión de la tendencia será el DCC. DC, cambio direccional; DCC, punto de confirmación DC; DCE, punto extremo DC; SO, rebasamiento

El resto de esta sección está organizado de la siguiente manera. La Sección 3.1 presenta la tarea de estimación de longitudes, donde usamos las Ecuaciones (1)–(3) para estimar la relación entre las longitudes DC y OS; La Sección 3.2 describe el paso de clasificación utilizado para predecir si hay un sistema operativo parejo o no; y finalmente, la Sección 3.3 presenta la estrategia comercial.

3.1 | Técnica de estimación de la longitud del sistema operativo

Como podemos observar en la Figura 2, nuestro marco consta de tres pasos principales: clasificación, estimación de la longitud del sistema operativo e integración de esta predicción en una estrategia comercial. Sin embargo, si tuviéramos que implementar el paso de clasificación primero, los errores cometidos en este paso se trasladarían al paso de estimación de la longitud del sistema operativo. Por ejemplo, supongamos que (1) un conjunto de datos consta de 10 eventos DC, 8 eventos DC son seguidos por un evento OS y 2 eventos DC no lo son; y (2), un clasificador predice que los 10 eventos DC tienen un evento OS correspondiente. En est

caso, cuando nos movemos al paso de estimación de longitud OS y aplicamos cualquiera de las Ecuaciones (1)–(3), el la información (datos) de los 10 eventos se utilizará para construir la estimación de la longitud del sistema operativo modelos, incluyendo incorrectamente la información de los dos eventos que ya conocemos que no van seguidos de eventos del sistema operativo.

Para evitar que este error de clasificación se lleve adelante, hemos realizado el tarea de estimación de longitud primero, antes del paso de clasificación, y bajo perfecta previsión en el datos de entrenamiento. Tener una previsión perfecta nos permite identificar los eventos de DC que se siguen por un evento OS y aplique las Ecuaciones (1)–(3) solo a esos datos. Como resultado, eliminamos la problema de los errores de clasificación que afectan al paso de estimación de longitud. Las ecuaciones (1)–(3) por lo tanto ahora excluye el ruido (es decir, eventos de CC sin un evento de sistema operativo correspondiente) y puede centrarse en los datos Eso importa. Por último, debemos tener en cuenta que debido a que realizamos la tarea anterior solo en el conjunto de entrenamiento, evitamos introducir sesgos cuando finalmente aplicamos la longitud seleccionada modelo de estimación a los datos de prueba (no vistos).

3.1.1 | OS CFactor2)

Este enfoque se basa en observaciones empíricas en el mercado Forex, lo que condujo a la creación de varias leyes de escala.¹⁰ De acuerdo con la referencia [10], la longitud del sistema operativo es en promedio el doble de la duración de su evento DC correspondiente. Por lo tanto, siempre que queramos predecir el OS, mida el DC relevante y multiplíquelo por 2. Debido al hecho de que la relación de longitud DC-OS depende de un factor de 2, llamamos a este enfoque Factor2.

Nos gustaría señalar una vez más que la confirmación de un cambio de tendencia, al alza a DC hacia abajo y viceversa, solo se detecta en retrospectiva, es decir, solo cuando se confirma el evento de DC correspondiente. Por lo tanto, usamos la fórmula anterior para predecir la longitud de el evento del sistema operativo y, por lo tanto, anticipar cuándo terminará la tendencia actual, solo cuando se produzca un evento de DC. confirmado y clasificado para tener un evento OS correspondiente.

3.1.2 | OS mDCFactorM)

Esta ecuación expresa una relación lineal entre las longitudes de DC y OS, donde M es un constante que denota la relación promedio de longitud de eventos DC/OS para un conjunto de datos dado. Porque OS es una aproximación y no tiene en cuenta el conjunto de datos subyacente, fórmula ofrece una estimación personalizada de la relación de longitud de evento DC:OS en un dato dado establecer. Dado que el factor que define la relación de longitud de DC-OS es igual a una constante m , llamamos a este enfoque FactorM. En este enfoque, la duración promedio de cada evento del sistema operativo en el se calcula el conjunto de entrenamiento. Además, existe una distinción entre la duración media de eventos del sistema operativo hacia arriba y hacia abajo. Esto se debe a que la relación DC:OS podría ser diferente para los dos tipos de tendencia.

Para una presentación detallada de este enfoque, remitimos al lector a la Referencia [28].

(3.1.3 | OS f€C I -) (Médico general)

Este enfoque utiliza un algoritmo GP para desarrollar un modelo de regresión simbólica (no) lineal para representan la relación entre las longitudes de DC y OS. Lo llamamos RegyGP. Contrariamente a

técnicas estándar de regresión lineal (p. ej., regresión lineal), donde ajustamos coeficientes bajo dado un modelo, la regresión simbólica nos permite determinar tanto la forma funcional del modelo, así como sus coeficientes. Esto tiene la ventaja de que no necesitamos hacer suposiciones sobre la relación entre la longitud de DC y OS. GP creará así matemáticas ecuaciones que describen la relación entre la longitud de DC y OS, sin hacer ninguna supuestos de su forma. Se basa en el principio darwiniano de la evolución, donde crea una población de programas no aptos (generalmente aleatorios) (ecuaciones que describen el DC-OS relación de longitud en nuestro caso) y busca en el espacio de expresiones matemáticas para encontrar modelos lineales y no lineales que mejor se ajusten al conjunto de datos. El método de cabecera es considerado uno de los los métodos del arte para la regresión simbólica.³⁰

La Tabla 1 presenta la configuración de la GP. La Figura 3 presenta dos árboles de muestra del GP que Haber creado. El primer árbol representa la ecuación que calcula la longitud del OS como $((DCI \hat{y} 2,5) \times 1,51) + (1.8 +) DCI$ y el segundo árbol representa la ecuación $((\frac{1.84}{\hat{y}^2}) + (\text{porque}(\hat{y}) - 1.22))$, donde DCI en ambas ecuaciones es la duración del evento DC.

La función de aptitud del GP es el error cuadrático medio (RMSE) entre el sistema operativo real longitud (OSI) y longitud OS estimada ($O \hat{S}$).

$$\hat{y} = \sqrt{\frac{\sum_{i=1}^n (\text{sistema operativo sistema operativo})^2}{n}}$$

(4)

donde n es el tamaño de la muestra.

Para una presentación detallada del algoritmo GP, remitimos al lector a la Referencia [12].

3.1.4 | Salidas de estimación de longitud del sistema operativo

Como hemos mencionado anteriormente, diferentes umbrales de DC generan diferentes resúmenes de DC. Seleccionamos los umbrales óptimos por conjunto de datos de un conjunto de umbrales. Para hacer esto, primero usamos cada umbral para generar su propio resumen DC. Luego, aplicamos cada una de las Ecuaciones (1)–(3) a cada resumen DC, y así obtener diferentes modelos de estimación de longitud OS, uno para cada ecuación y resumen DC. Finalmente, clasificamos cada modelo por RMSE. Tenga en cuenta que el proceso de cada ecuación es independiente entre sí; por lo tanto, cada ecuación devuelve una longitud de sistema operativo diferente modelo de estimación y resumen DC.

El proceso anterior devuelve tres salidas: (i) el mejor modelo de estimación de longitud de OS, (ii) el mejor umbral, y (iii) el respectivo resumen de DC de ese umbral en particular. Figura 4 ilustra este proceso.

TABLA 1 Configuración del algoritmo GP

Configuración	Valor
Conjunto de funciones	+, \hat{y} , /, *, sin, cos, pow, log, exp.
Juego de terminales	DCI, constante aleatoria efímera.
operación genética	elitismo, cruce de subárboles, mutación de subárboles.




FIGURA 3 Ejemplos de árboles de programación genética

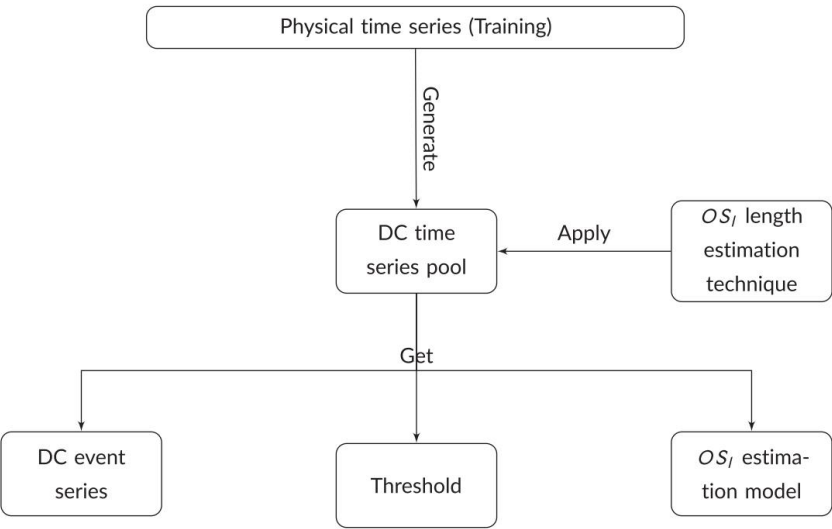


FIGURA 4 Marco propuesto para obtener un modelo de estimación de longitud de OS y seleccionar eventos de umbral y DC con una alta relación de eventos DC:OS. DC, cambio direccional; SO, rebasamiento

3.2 | Paso de clasificación

El siguiente paso es predecir si un evento DC es seguido por un evento OS ($\check{y}DC$) o no ($\check{y}DC$). Para este paso, utilizamos AutoWeka,³¹ que es una herramienta de aprendizaje automático automatizado que busca en el espacio de 39 algoritmos de clasificación y sus hiperparámetros. Ejecutamos AutoWeka 10 veces para cada conjunto de datos y seleccionamos el algoritmo con la medida f más alta. Para evitar sesgos, aplicamos una validación cruzada de 10 veces al conjunto de entrenamiento; por lo tanto, no exponemos el equipo de prueba a AutoWeka. El proceso anterior nos permite obtener un clasificador personalizado con hiperparámetros personalizados para cada conjunto de datos.

Los clasificadores se entrenan en seis atributos basados en DC. Estos son: diferencia entre el precio de los puntos upturn/downturn y DCC (DC confirm) (A1); diferencia entre el tiempo de subida/bajada y los puntos DCC (A2); velocidad de cambio de precios desde el inicio de una tendencia y punto DCC (A3); precio en puntos de confirmación anteriores (A4); información (booleana) sobre si el evento DC inmediatamente anterior tiene un evento OS correspondiente o no (A5); (booleano) indicación de si la hora de inicio y fin de un evento DC son iguales (A6). Atributos A1 y A2

TABLA 2 Atributos de clasificación

Nombre de atributos		Descripción
A1	Precio DC	Diferencia de precio entre el punto de subida/bajada y el cambio de dirección punto de confirmación.
A2	tiempo DC	Diferencia de tiempo entre el punto de subida/bajada y el cambio de dirección punto de confirmación.
A3	<i>Sigma'</i>	Velocidad a la que cambian los precios desde el inicio de una tendencia hasta los cambios de dirección punto de confirmación.
A4	DCtÿ1price	Precio en puntos de confirmación anteriores.
A5	DCT-1OS	Indica si el evento DC inmediatamente anterior tiene un sistema operativo correspondiente evento o no.
A6	FlashEvent	Indica si la hora de inicio y la hora de finalización del evento DC son iguales o no.

se introdujeron en la Referencia [10], mientras que A3–A6 se introdujeron por primera vez en la Referencia [32]. La Tabla 2 resume estos atributos.

La Figura 5 resume el proceso de clasificación. Después de obtener la salida de la longitud del sistema operativo proceso de estimación presentado en la Figura 4, a saber, "Mejor serie de eventos de DC", lo usamos para calcular los valores de los atributos A1–A6. Luego, usamos AutoÿWeka en el conjunto de entrenamiento para obtener el mejor modelo de clasificación por conjunto de datos.

Cada modelo de clasificación obtenido hará predicciones en el conjunto de pruebas (invisible) en si un evento DC es seguido por un evento OS. Si este es el caso, entonces usaremos una longitud de SO modelo de estimación (1)–(3), que analizamos en la Sección 3.1, para predecir el punto de inversión de la tendencia (es decir, la suma de la longitud de DC y OS). Si el modelo de clasificación predice que no hay evento OS correspondiente, el final del evento DC actual se convierte en el final de la tendencia. Este El proceso también se resumió en la Figura 2.

3.3 | estrategia comercial

Hasta ahora, hemos utilizado los pasos de estimación de tendencia de clasificación y OS para predecir el final de un tendencia. El último paso de nuestro marco es incorporar la predicción de inversión de tendencia en una negociación estrategia, de modo que podamos probar su eficacia informando métricas financieras, como retorno y desempeño del riesgo. A continuación, proporcionamos información de nuestra estrategia comercial.

3.3.1 | Visión general

Antes de presentar los detalles de nuestra estrategia comercial propuesta, debemos definir dos importantes nociones: abrir y cerrar una posición. Abrimos (cerramos) una posición cuando vendemos (compramos) la base divisa (por ejemplo, GBP) y comprar (vender) la divisa cotizada (por ejemplo, JPY).

Para abrir una posición, hay dos requisitos: (i) no hay una posición ya abierta, y (ii) el rendimiento de abrir la posición sería positivo, después de tener en cuenta costos de transacción. Si se cumplen los requisitos anteriores, abrimos una posición en el punto extremo de

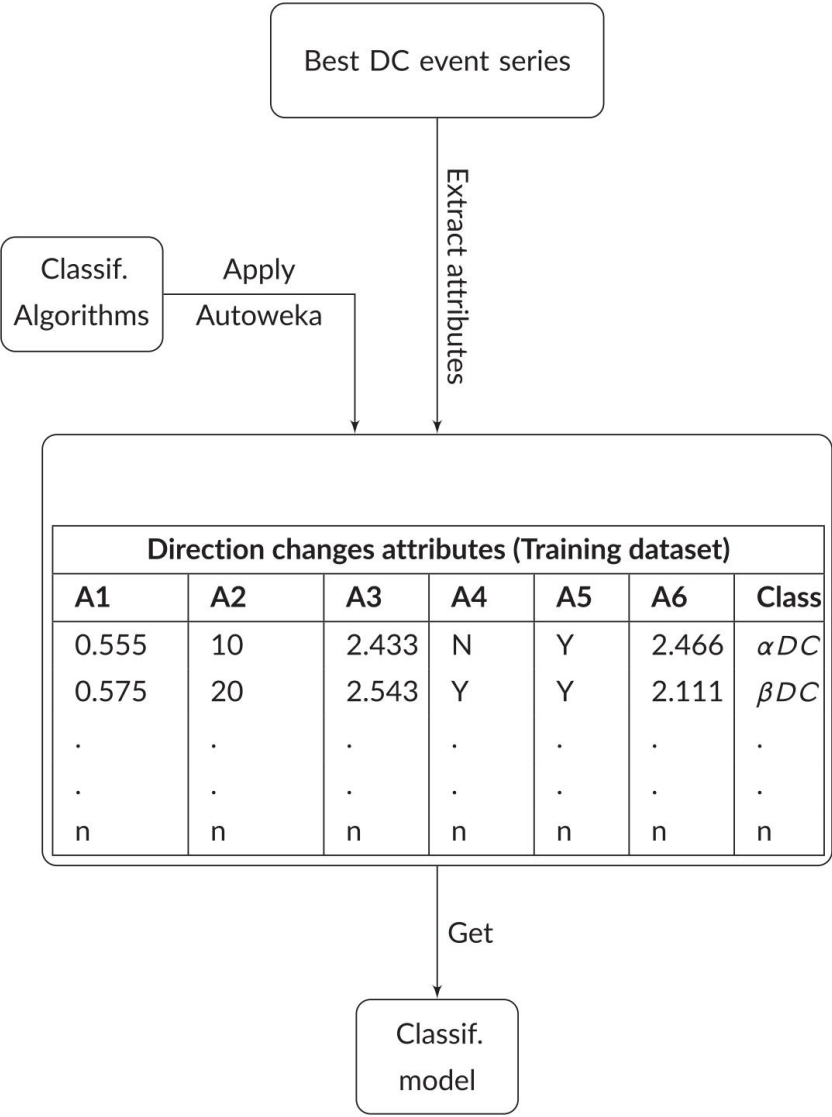


FIGURA 5 Marco propuesto para crear un modelo de clasificación para predecir si un evento DC es seguido por un evento OS ($\ddot{y}DC$) o no ($\ddot{y}DC$). DC, cambio direccional; SO, rebasamiento

una tendencia alcista de DC. De manera similar, para cerrar una posición, hay dos requisitos que deben mantenerse: (i) hay una posición abierta existente, y (ii) el rendimiento del cierre de la posición sería positivo después de contabilizar los costos de transacción. Si estas condiciones se mantienen, cerramos la posición en el punto extremo de una tendencia de CD a la baja.

El punto extremo en los dos casos anteriores puede estar en $\ddot{y}DC$ o $\ddot{y}DC$, dependiendo de la predicción del modelo de clasificación. Cuando no se cumplen los requisitos anteriores, no se realiza ninguna negociación. Todas las transacciones se realizan utilizando todo nuestro capital. El valor del costo de transacción es 0.025% por cada transacción. Los algoritmos 1 y 2 proporcionan una descripción detallada de las estrategias de apertura y cierre.

Algoritmo 1 Regla comercial para vender moneda base

Requerir: regla de venta

si DC está en tendencia alcista && No hay posición abierta entonces

 si Is $\dot{y}DC$ && Return no es negativo, abra una posición en el punto DCC

de lo contrario, si es $\dot{y}DC$ && la tendencia DC no se invierte antes del punto DCE estimado && el retorno no es negativo, entonces

 Abrir una posición en el punto DCE estimado

 más Mantener

terminara si

terminara si

Algoritmo 2 Regla comercial para comprar moneda base

Requerir: regla de compra

si la tendencia DC es a la baja && Hay una posición abierta, entonces

 si Is $\dot{y}DC$ && Return no es negativo, entonces Cerrar posición en el punto DCC

de lo contrario, si es $\dot{y}DC$ && la tendencia DC no se invierte antes del punto DCE estimado && el retorno no es negativo, entonces

 Cerrar posición en el punto DCE estimado

 más Mantener

terminara si

terminara si

3.3.2 | Evaluación de la estrategia comercial

Nuestra estrategia comercial se evalúa mediante tres métricas: rendimiento, reducción máxima (MDD) y proporción aguda. El retorno (Ecuación 5) se calcula después de contabilizar los costos de transacción. MDD (Ecuación 6) mide el riesgo a la baja calculando la pérdida máxima observada de un precio máximo a un mínimo antes de que se alcance un nuevo máximo. Finalmente, la razón de Sharpe (Ecuación 7) informa el rendimiento ajustado al riesgo, después de contabilizar el rendimiento por un activo libre de riesgo (por ejemplo, un bono del gobierno a una tasa de 0,25%).

$$RQ = \frac{TC}{Q} \cdot \frac{FXrate}{i} \cdot \frac{R}{\sigma} \tag{5}$$

donde Q es la cantidad de negociación, TC es el costo de transacción y FXrate es el precio que la transacción tiene lugar

$$MDD = \frac{P_{peak} - P_{trough}}{P_{trough}} \tag{6}$$

donde P_{trough} es el precio en el punto mínimo y P_{peak} es el precio en el punto máximo.

$$Relaci3n\ de\ Sharpe = \frac{R - R_{free}}{\sigma} \tag{7}$$

donde R es el rendimiento, i es el valor del activo libre de riesgo y $\dot{y}retorno$ es la desviaci3n est3ndar de el regreso.

4 | CONFIGURACIÓN EXPERIMENTAL

Los conjuntos de datos utilizados en nuestros experimentos consisten en datos de alta frecuencia (intervalo de 10 min) durante 16 Pares de divisas FX de marzo de 2016 a febrero de 2017 y cuatro pares de divisas adicionales de junio de 2013 a mayo de 2014. Estos pares se presentan en la Tabla 3. Cada mes se considera como un conjunto separado de tiempo físico. Usamos los primeros 2 meses para cada par de divisas para el parámetro ajuste, que resultó en 200 conjuntos de datos (5 umbrales DC x 20 pares de divisas x 2 meses). los Los 10 meses restantes para cada conjunto de datos se utilizaron para los experimentos principales, lo que resultó en 1000 conjuntos de datos (5 umbrales DC x 20 pares de divisas x 10 meses). Todos los conjuntos de datos estaban usando un 70:30 dividido entre conjuntos de entrenamiento y prueba.

Como cada umbral produce un resumen de DC diferente, evaluaremos cinco DC diferentes. umbrales para todos los conjuntos de datos (tanto sintonizados como no sintonizados). Estos umbrales son los mejores umbrales seleccionados dinámicamente durante el paso de estimación de la longitud del sistema operativo (consulte la Sección 3.1). Cuando informando los resultados en la Sección 5, presentaremos el rendimiento medio de cada algoritmo, sobre los cinco umbrales de DC.

4.1 | Ajuste de parámetros

Hay dos tareas que requieren ajuste de parámetros: la tarea de clasificación y la longitud del sistema operativo tarea de estimacion Como ya hemos mencionado, la tarea de clasificación utiliza Auto-Weka para buscar en el espacio de los algoritmos y sus hiperparámetros. El único parámetro que tenemos necesario ajustar era el tiempo de ejecución de AutoWeka. Los tiempos de ejecución más altos permiten a AutoWeka considere más algoritmos y más configuraciones de hiperparámetros. Consideramos cinco diferentes tiempos de ejecución: 15, 30, 45, 60 y 75 min. Después de los experimentos en un conjunto de entrenamiento y validación, elegimos la duración de 60 min en función de los resultados promedio de la medida f.

Con respecto a la tarea de estimación de la longitud del SO, el único ajuste necesario fue para el GP algoritmo (Ecuación 3). Usamos el paquete I/F-Race, Referencia [33] que implementa un

TABLA 3 Pares de divisas FX utilizados en nuestros experimentos

pares de divisas		pares de divisas	
Marzo 2016 a Febrero 2017			
USD/JPY	\$ australiano/Japón. Yen	EUR/NOK	Euro/Corona noruega
USD/NZD	\$/N australiano. Celo.	\$ GBP/USD	Libra esterlina/\$ australiano
AUD/USD	\$ australiano/US\$	NZD/USD	Nueva Zelanda \$/US \$
USD/JPY	\$ canadiense/Japón. Yenes	USD/CAD	\$ EE.UU./\$ canadiense
EUR/USD	euro/dólar australiano	USD/NOK	US \$/Corona noruega
EUR/GBP	euro/libra esterlina	USD/JPY	US\$/Japón. Yen
USD/USD	euro/dólar canadiense	USD/EUR	US \$/dólar singapurense
USD/CSK	euro/corona checa	EUR/ZAR	US \$/rand sudafricano
junio de 2013 a mayo de 2014			
EUR/USD	Euro/US\$	EUR/CHF	Libra esterlina/Franco suizo
EUR/JPY	Euro/Japón. Yen	GBP/USD	Libra esterlina/US\$

método de carreras para seleccionar la mejor configuración de un algoritmo de optimización. Presentamos los parámetros de GP seleccionados en la Tabla 4.

4.2 | Configuración experimental comercial

Como ya hemos mencionado, después de completar las tareas de clasificación y estimación de la longitud del sistema operativo, podemos usar las Ecuaciones (1)–(3) para predecir cuándo terminará una tendencia DC. Incorporamos estas ecuaciones en la estrategia comercial que presentamos en la Sección 3.3.

Nuestro objetivo es investigar si la introducción del paso de clasificación es beneficiosa para el rendimiento comercial. Por lo tanto, compararemos cada algoritmo DC con una versión con y sin clasificación. Además, también experimentaremos con algoritmos que no sean DC, para investigar cómo se compara el rendimiento de DC con otros algoritmos comerciales de última generación.

Presentamos a continuación todos los algoritmos utilizados en nuestros experimentos.

4.2.1 | Puntos de referencia relacionados con DC

(C+) Factory2. Presentado originalmente en la referencia [10], este enfoque de inversión de tendencia de CC dice que, en promedio, la duración del evento del sistema operativo es el doble de la duración del evento de CC. En esta estrategia, la Ecuación (1) reemplaza los pasos de clasificación y regresión de nuestra metodología. Por lo tanto, el punto de inversión de la tendencia es el punto en el que la duración del evento del sistema operativo es el doble de la duración del DC. Factory2 es el enfoque sin clasificación, y C+Factory2 es el mismo enfoque con clasificación.

(C+) FactoryM. Este es un enfoque de inversión de tendencia DC presentado originalmente en la Referencia [28], donde la relación DC-OS se expresa mediante una función lineal. La constante *M* se adapta a cada conjunto de datos y describe la relación lineal anterior. En esta estrategia, usamos la Ecuación (2) en lugar de los pasos de clasificación y regresión de nuestra metodología. Por lo tanto, el punto de inversión de la tendencia se adapta a cada conjunto de datos. FactoryM es el enfoque sin clasificación, y C+FactoryM es el mismo enfoque con clasificación.

(C+) RegyGP. Este es un enfoque de inversión de tendencia DC presentado en la Referencia [12], donde las ecuaciones se crean mediante un GP de regresión simbólica. En esta estrategia comercial, incorporamos la Ecuación (3). RegyGP es el enfoque sin clasificación, y C+RegyGP es el mismo enfoque con clasificación.

TABLA 4 Parámetros de GP

Parámetro	
Población	500
Generación	37
Tamaño del torneo	3
Probabilidad de cruce	0.98
Probabilidad de mutación	0.02
Profundidad máxima	3
elitismo	0.10

comercio p. Obtenemos la probabilidad p del conjunto de entrenamiento de que un evento DC sea seguido por un evento OS. En el punto DCC, decidimos con esta probabilidad p si una tendencia DC tiene un evento OS correspondiente; si es cierto, aplicamos cualquiera de los tres modelos de estimación de longitud de OS anteriores para estimar la duración del evento de OS (es decir, predecir el punto de inversión de la tendencia, que es nuestro punto extremo de cambio direccional estimado). Si es falso, el punto DCC es el punto extremo estimado y aplicamos la estrategia comercial y vemos si una operación en ese punto puede ser rentable. La motivación detrás de este escenario es demostrar que la introducción del paso de clasificación es ventajoso y supera la decisión informada de tener o no tener un evento OS, basado en una probabilidad que se adapta al conjunto de entrenamiento. Como hay tres modelos diferentes de estimación de la longitud del sistema operativo, hay como resultado tres variaciones del punto de referencia comercial personalizado:

- $p + \text{Factor} \gamma_2$.
- $p + \text{Factor} \gamma_M$.
- $p + \text{Reg} \gamma_{GP}$.

Comercio en el punto DCC. En este escenario, siempre operaremos tan pronto como se confirme un cambio de dirección, es decir, en el DCC. La motivación detrás de este escenario es investigar la rentabilidad comercial si no tuviéramos en cuenta los eventos del sistema operativo en absoluto y, en cambio, solo nos centráramos en los eventos de DC. Siempre que nuestros algoritmos de clasificación propuestos superen este escenario, nuevamente demostraría que la introducción del paso de clasificación es ventajoso y mejor que no tener clasificación y el conocimiento de la longitud del sistema operativo.

Como hay tres modelos diferentes de estimación de la longitud del sistema operativo, hay como resultado tres variaciones del punto de referencia comercial aleatorio:

- $\text{DCC} + \text{Factor} \gamma_2$.
- $\text{DCC} + \text{Factor} \gamma_M$.
- $\text{DCC} + \text{Reg} \gamma_{GP}$.

4.2.2 | Puntos de referencia no DC

Estrategia comercial de análisis técnico. También utilizamos tres indicadores técnicos populares para tomar decisiones comerciales. Estos indicadores son:

- Índice de fuerza relativa (RSI).
- Indicador de media de movimiento exponencial (EMA).
- Divergencia de convergencia de la media móvil (MACD).

Comprar y retener. Comprar y mantener es un punto de referencia bien conocido para los algoritmos comerciales. En el primer mes del conjunto de datos sin ajuste, compramos la moneda cotizada; después del final del período de 10 meses, vendemos a cambio de la moneda base.

5 | RESULTADO Y ANÁLISIS

En esta sección presentamos los resultados de nuestro trabajo experimental. Primero presentamos los resultados de la regresión en la Sección 5.1 y luego presentamos los resultados comerciales en la Sección 5.2.

Nos gustaría recordar al lector que el objetivo de nuestro trabajo es doble: (i) Demostrar que la introducción del paso de clasificación puede mejorar significativamente la rentabilidad de las estrategias basadas en DC, y (ii) Demostrar que las estrategias basadas en DC, que use un paso de clasificación para predecir si un evento de DC es seguido por un evento de OS, puede ser rentable y superar otras estrategias comerciales de DC y no basadas en DC.

5.1 | resultado de la regresión

La Tabla 5 presenta el resultado promedio de RMSE del paso de estimación de longitud OS sobre los cinco umbrales de DC y los 10 meses de datos por par de divisas para GP \ddot{y} Reg, Factor \ddot{y} M y Factor \ddot{y} 2. Para cada uno de estos tres algoritmos, presentamos el RMSE para dos variaciones: (1) con el paso de clasificación y (2) sin el paso de clasificación. Para la variación que incluye el paso de clasificación (denotado con el prefijo C+), estimamos la duración del evento OS solo en las tendencias de DC que han sido clasificadas como \ddot{y} DC. RMSE se calcula independientemente de la predicción de la clasificación (es decir, si es correcta o incorrecta). En los casos en que el algoritmo de clasificación predice incorrectamente que hay un evento de OS, la longitud devuelta por el algoritmo de estimación de OS se compara con la longitud cero (0). Cuando el algoritmo de clasificación predice incorrectamente que no hay un evento del sistema operativo, la duración del evento del sistema operativo se compara con la longitud cero (0). En otras palabras, en ambos casos, las predicciones incorrectas (FP, FN) del paso de clasificación se contabilizan para el RMSE.

En la Tabla 5 podemos observar que C+Reg \ddot{y} GP tiene el RMSE promedio más bajo (18,6170) en los seis algoritmos. C+Reg \ddot{y} GP también tiene 11 casos (de los 20 pares de divisas) que generaron el RMSE más bajo por par de divisas, Reg \ddot{y} GP tuvo cuatro casos de este tipo, C+Factor \ddot{y} M tres casos y C+Factor \ddot{y} 2 dos casos. Más importante aún, podemos observar que el RMSE promedio para cada algoritmo con el paso de clasificación ha arrojado un RMSE promedio más bajo en comparación con su respectiva variación sin clasificación: C+Reg \ddot{y} GP (18.6550) versus Reg \ddot{y} GP (20.3216), C+ Factor \ddot{y} M (20,5592) versus Factor \ddot{y} M (34,4474), y C+Factor \ddot{y} 2 (21,3247) versus Factor \ddot{y} 2 (25,7951). También vale la pena señalar que la precisión de la clasificación (presentada entre paréntesis) es bastante alta, por lo general oscila entre el 70 % y el 85 %. Como hemos planteado, la alta precisión parece haber jugado un papel importante en la reducción del RMSE promedio para los tres algoritmos (Reg \ddot{y} GP, Factor \ddot{y} M y Factor \ddot{y} 2).

Una observación interesante es que, si bien el par EUR/CSK tiene una precisión de clasificación relativamente baja en todas las variantes (55 %–58 %), su RMSE promedio aún supera a las variantes sin el paso de clasificación. Analizamos esto más a fondo y descubrimos que el par de divisas EUR/CSK tiene la cantidad más baja de eventos DC (55 en el conjunto de entrenamiento y 18 en el conjunto de prueba), mientras que la cantidad promedio de eventos DC para todos los demás pares de divisas es 194 en entrenamiento y 60 en prueba. Además, la duración de los eventos de DC (es decir, la cantidad de puntos de datos de tiempo físico que componen un solo evento) es la más alta para EUR/CSK (46 en entrenamiento y 32 en prueba), en comparación con un promedio de 12 tanto en entrenamiento como en prueba. prueba para todos los demás pares de divisas. Esto significa que el EUR/CSK experimenta un número menor de eventos DC, seguidos de eventos OS largos. Cuando los algoritmos se ejecutan sin el paso de clasificación, se supone que cada evento DC va seguido de un evento OS largo. Dado que los eventos DC son largos para EUR/CSK, como consecuencia, los eventos OS también son largos. Por lo tanto, cada vez que un algoritmo de estimación de longitud de OS (Reg-GP, Factor-M y Factor-2) hace una predicción cuando no hay un evento de OS, esto da como resultado un RMSE mayor. El paso de clasificación, aunque tiene una menor precisión (55%-58%), reduce significativamente el RMSE simplemente al reducir la cantidad de veces que se usa el algoritmo de estimación OS cuando hay

TABLA 5 Valores promedio de RMSE para cada algoritmo estimador de longitud de SO medidos en 1000 conjuntos de datos que consta de cinco umbrales diferentes generados dinámicamente adaptados a cada conjunto de datos de DC, 20 pares de divisas y 10 meses de datos de intervalo de 10 minutos para cada par de divisas

Algoritmos	C+RegyGP	Reg-GP	C+Factor-M	Factor-M	C+Factor-2	Factor2
USD/JPY	15,5670 (0,851)	15,6270	17,1570 (0,778)	25,5270	18,4720 (0,782)	22,2690
USD/NZD	27.368 (0.805)	24,3320	27,4110 (0,806)	51,2420	31,9260 (0,761)	41,5920
AUD/USD	11,5800 (0,829)	12,8140	12,7200 (0,768)	16,0950	11,8270 (0,745)	14,0600
USD/JPY	11,8430 (0,820)	18,7850	14,6860 (0,779)	39,9700	16,8800 (0,764)	27,2510
EUR/USD	21,1710 (0,821)	20,5690	20,2010 (0,799)	25,7280	14,7520 (0,751)	19,7490
USD/USD	16,2050 (0,839)	17,7190	21,0950 (0,784)	23,1830	22,6420 (0,750)	24,8670
USD/CSK	41,9900 (0,557)	52,9490	46,0270 (0,581)	188,6080	63,0420 (0,565)	83,8450
EUR/GBP	24,1730 (0,825)	22,6350	25,5870 (0,766)	31,4300	17,2120 (0,752)	18,7900
EUR/JPY	19,9650 (0,821)	21,1170	23,4540 (0,758)	28,1620	23,1640 (0,748)	25,2040
USD/NOK	13,7170 (0,818)	13,7620	20,4120 (0,727)	27,2010	19,5710 (0,728)	22,4990
EUR/USD	28,2600 (0,806)	31,0610	26,8990 (0,786)	38,5320	27,6690 (0,762)	30,0380
GBP/EUR	15,1380 (0,837)	14,7190	19,2820 (0,832)	21,6700	14,8810 (0,780)	17,9100
EUR/CHF	15,9610 (0,831)	17,2040	17,5260 (0,784)	19,3580	21,4210 (0,769)	23,6690
GBP/USD	19,2040 (0,851)	24,8890	17,8250 (0,790)	21,2230	25,3210 (0,746)	27,7780
NZD/USD	10,2300 (0,848)	10,5880	11,0920 (0,772)	14,7310	13,1350 (0,773)	15,8960
Entre estadísticas de clasificación	26,9340 (0,797)	26,8180	27,1330 (0,766)	34,6540	27,5190 (0,739)	29,3150
USD/JPY	13,7040 (0,850)	14,5430	15,9860 (0,774)	17,9980	16,0310 (0,777)	18,3260
USD/NOK	7.7180 (0.887)	7.3570	9,96900 (0,813)	14,1280	8.1830 (0.792)	10.7640
USD/EUR	26,9320 (0,780)	34,1480	31,9440 (0,799)	41,7120	27,4980 (0,720)	34,3600
EUR/ZAR	5.4400 (0.877)	4.7960	4.7770 (0.807)	7.7960	5.3470 (0.813)	7.7200
RMSE medio	18,8175 (0,816)	20,5687	20,7382(0,773)	34.9169	21,4748 (0,749)	25,9807

Nota: Entre paréntesis también informamos la precisión de la clasificación, como referencia (para C+RegyGP, C+FactorM y C+Factor2). El mejor valor para cada fila (par de divisas) se muestra en negrita.

ningún evento del sistema operativo. En este caso, el paso de clasificación no debe evaluarse únicamente en función de los méritos de precisión de la clasificación, sino del efecto real que tiene sobre el error de regresión.

Para comprender mejor los resultados anteriores, hemos realizado el método no paramétrico de Friedman prueba estadística, bajo la hipótesis nula de que todos los algoritmos provienen de la misma distribución. Presentamos estos resultados en la Tabla 6. La primera columna presenta el rango promedio de cada algoritmo. La segunda columna presenta el valor p ajustado de la prueba cuando el rango promedio de los algoritmos se compara con el rango promedio del algoritmo de control (es decir, algoritmo con el mejor rango). El valor p ajustado se calcula con el post-hoc de Hommel prueba. Como podemos observar, C+RegyGP ocupa el primer lugar y supera estadísticamente a todos los demás algoritmos. en el nivel $\tilde{y} = 0,05$. Más importante aún, C+Reg-GP supera a Reg-GP, C+Factor-2 supera a Factor-2, y C+Factor-M supera a Factor-M.

TABLA 6 Resultados de la prueba estadística de estimación de longitud OS según la prueba no paramétrica de Friedman con la prueba post-hoc de Hommel

Algoritmo	Rango promedio	<i>AjustarpHommel</i>
C+RegyGP (c)	1,90	–
RegyGP	2.50	0.3105
C+FactorM	2.95	0.1518
C+Factor2	3.15	0.1038
Factor2	4.90	1.5835Ey6
FactorM	5.60	1.9985Ey9

Nota: Las diferencias significativas al nivel $\gamma = 0,05$ se muestran en negrita.

En resumen: (i) introducir el paso de clasificación (C+RegyGP, C+FactorM, y C+Factor-2) a los algoritmos basados en DC existentes (Reg-GP, Factor-M y Factor-2) ha reducido el error predictivo promedio, y (ii) los algoritmos DC que utilizan el paso de clasificación superan a sus respectivo algoritmo sin clasificación. Nuestro interés ahora cambia al paso comercial para investigar si la introducción del paso de clasificación también conduce a un aumento en los márgenes de beneficio comercial (en además de reducir el error de estimación de la longitud del sistema operativo, como acabamos de ver en la Sección 5.1).

5.2 | resultado comercial


5.2.1 | Comparación con algoritmos de análisis técnico y basados en DC

La Tabla 7 presenta los rendimientos promedio por par de divisas. Cuando se informa el valor 0.00, significa que la estrategia comercial tomó una acción de espera durante el periodo de 10 meses. El mejor valor para cada fila (par de divisas) se muestra en negrita. El mejor valor entre las diferentes variantes del mismo algoritmo (Reg-GP, Factor-M y Factor-2) está subrayado, es decir, para AUD/NZD C+Reg-GP tiene el mejor rendimiento en todos los algoritmos, así como entre las variantes del algoritmo RegyGP, a saber, C+Reg-GP, Reg-GP, p+Reg-GP y DCC+Reg-GP.

En términos de resultados promedio, C+RegyGP tiene el rendimiento más alto (0.2247) en todos los algoritmos. Además, todas las versiones que han introducido el paso de clasificación tienen el promedio más alto rendimiento para su grupo respectivo (C+RegyGP: 0,2247, C+FactorM: 0,0684 y C+Factor2: 0,1186). También es importante señalar que estas tres versiones muestran un fuerte promedio positivo rendimiento, mientras que todos los demás algoritmos experimentan rendimientos promedio negativos, con la excepción solo de Factor-2, que muestra retornos promedio marginalmente positivos de 0.0260. también vale la pena destacando que el mercado Forex está abierto las 24 horas del día en diferentes partes del mundo y en cualquier punto en el tiempo, hay al menos un mercado abierto y tiene mercados abiertos superpuestos durante algunas horas. Así, un retorno promedio de la escala de 0.2247% (C+RegyGP) después de descontar el costo de transacción tendrá un efecto acumulativo significativo a largo plazo.

Al observar más de cerca los pares de divisas individuales, podemos observar que C+RegyGP supera RegyGP, p+RegyGP y DCC+RegyGP en 14 de los 17 pares (los tres pares restantes tienen 0,00 devolución, por lo que no se produjo ninguna negociación). De manera similar, para el segundo grupo de algoritmos DC, C+Factor-M ocupa el primer lugar con 13 casos. Por último, C+Factor2 tuvo el rendimiento más alto en 10 pares de divisas.

Para respaldar nuestros hallazgos, aplicamos la prueba estadística no paramétrica de Friedman. La hipótesis nula es que los algoritmos provienen de la misma distribución continua. el resultado de la



La prueba estadística presentada en la Tabla 8 muestra que las tres versiones de DC con el paso de clasificación (es decir, C+Reg̃GP, C+Factor̃M y C+Factor̃2) clasifican como los más altos y superan a todos los demás variantes sin el paso de clasificación. Además, C+Reg-GP ocupa el primer lugar y supera estadísticamente a todos los algoritmos, además de C+Factor-M y C+Factor-2, con un nivel de significancia del 5 %.

Aunque C+Reg̃GP registró rendimientos más altos que otras estrategias comerciales, también es importante tener en cuenta el riesgo asumido para lograrlo. Por ello, también presentamos resultados de MDD (maximum drawdown) y ratio de Sharpe. No registramos medidas de riesgo para par de divisas AUD/JPY, CAD/JPY y USD/JPY, ya que no se realizaron transacciones en estos mercados.

La Tabla 9 presenta el resultado de MDD. En términos de MDD promedio general, C+Reg̃GP tiene la menor (mejor) valor medio de 0,1259. En términos de pares de divisas individuales y rendimiento de cada grupo de algoritmo, podemos observar que C+Reg̃GP devolvió el valor MDD más bajo en 13 de los 17 casos, en comparación con Reg̃GP, p+Reg̃GP y DCC+Reg̃GP. Así que una vez más, el la introducción del paso de clasificación ha sido beneficiosa. Lo interesante, sin embargo, es el resultados para los otros dos conjuntos de algoritmos, Factor-M y Factor-2. Parece que hay una compensación aquí entre mayor rendimiento y riesgo, ya que en ambos casos, es en realidad la variante sin el paso de clasificación que ocupa el primer lugar en su grupo respectivo (tanto el Factor-M como el Factor-2 ocupan el primer lugar en 15 de los 17 pares de divisas). Las variantes de clasificación ocuparon el segundo lugar en ambos grupos.

Además, la Tabla 10 presenta la prueba de Friedman para la Tabla 9. La hipótesis nula es nuevamente que los algoritmos provienen de la misma distribución continua. Como podemos observar, lo mejor algoritmo de clasificación es uno que incluye un paso de clasificación, C+Reg̃GP, y estadísticamente supera a otros nueve algoritmos en el nivel de significancia del 5%.

TABLA 8 Resultados de la prueba estadística de retornos promedio según la prueba no paramétrica de Friedman con el Prueba post hoc de Hommel

Estrategias comerciales	rango promedio	<i>AjustarpHommel</i>
C+Reg̃GP (c)	2.8571	–
C+Factor̃M	4.7619	0.1675
C+Factor̃2	4.8095	0.1675
Factor̃2	6.6190	0.0192
p+Factor̃M	7.7142	0.0017
p+Factor̃2	7.8095	0.0017
RSI	8.1904	6.6827Ẽ4
DCC+Factor̃2	8.1904	6.6827Ẽ4
DCC+Factor̃M	8.5238	2.9701E-4
Reg̃GP	8.5714	2.7736Ẽ4
p+Reg̃GP	9.4762	1.6190E-5
DCC+Reg̃GP	9.6190	9.6100Ẽ6
Factor̃M	10.0952	1.8805E-6
EMA	10.6190	2.4251Ẽ7
MACD	12.1429	2.4059Ẽ10

Nota: intervalo de diez minutos fuera de la fecha de la muestra. Diferencias significativas entre el algoritmo de control (indicado con (c) y el los algoritmos representados por una fila en el nivel $\tilde{y} = 5\%$ se muestran en negrita, lo que indica que el valor de p ajustado es inferior a 0,05.




TABLA 10 Resultados de las pruebas estadísticas de la reducción máxima de las estrategias comerciales basadas en DC de acuerdo con el prueba no paramétrica de Friedman con la prueba postñhoc de Hommel

Estrategias comerciales	rango promedio	AjustarpHomm
C+RegÿGP (c)	3.1111	–
FactorÿM	4.0556	0.5264
RSI	4.4111	0.5264
RegÿGP	4.6111	0.5264
EMA	5.2778	0.5264
Factorÿ2	5.3333	0.5264
MACD	4.3889	0.5061
C+FactorÿM	8.1111	0.0056
C+Factorÿ2	8.8889	8.5002Eÿ4
p+RegÿGP	9.6111	1.1688Eÿ4
p+FactorÿM	11.2778	9.8595E-7
p+Factorÿ2	11.0556	4.7220Eÿ7
DCC+RegÿGP	12.2222	1.1813E-8
DCC+Factorÿ2	12.7778	1.1566Eÿ9
DCC+FactorÿM	14.1667	1.6862Eÿ12

Nota: Datos fuera de la muestra en intervalos de diez minutos. Diferencias significativas entre el algoritmo de control (indicado con (c) y el los algoritmos representados por una fila en el nivel ÿ = 5% se muestran en negrita, lo que indica que el valor de p ajustado es inferior a 0,05.

La figura 6 ilustra el índice de Sharpe de las estrategias comerciales. El período de tiempo se presenta en el eje x, y la relación aguda en el eje y. Los pares donde no hay valores son los donde no se negociaba. Como podemos observar, C+RegÿGP reporta consistentemente una nitidez positiva proporción, mientras que las otras estrategias tienen una mezcla de valores positivos y negativos. Ahí son 34 resúmenes de rentabilidad ajustada al riesgo, excluyendo los seis períodos en los que no se realizó negociación. De los 34, C+RegÿGP tuvo un índice de Sharpe positivo en 28; Mientras tanto, RegÿGP, p+RegÿGP, DCC +Reg-GP, C+Factor-M, Factor-M, p+Factor-M, DCC+Factor-M, C+Factor-2, Factor-2, p+Factorÿ2, DCC+Factorÿ2, EMA, MACD y RSI tenían 11, 15, 8, 22, 7, 19, 13, 21, 17, 14, 13, 8, 4 y 11 respectivamente. De los 28 resultados positivos del índice de Sharpe, 6 por encima de 0,5, 18 fueron por encima de 0,2 y menos de 0,5; el resto estuvo por debajo de 0.2.* Tabla 11, que presenta la prueba de Friedman para el resultado presentado en la Figura 6, confirma nuestros hallazgos, ya que C+RegÿGP ocupa el primer lugar y supera estadísticamente a todas las demás estrategias comerciales en el nivel del 5%. Además, C+FactorÿM y C+Factorÿ2 ocupan el segundo y tercer lugar, respectivamente, lo que nuevamente demuestra que la introducción del paso de clasificación es beneficiosa para los algoritmos de DC.

5.2.2 | Comparación con comprar y mantener

En términos de rentabilidad y riesgo, dado que C+RegÿGP resultó ser el mejor algoritmo en comparación a otros algoritmos de análisis técnico y DC, ahora cambiamos nuestro enfoque para compararlo con el



FIGURA 6 Relación de Sharpe promedio para todos los pares de divisas [La figura en color se puede ver en wileyonlinelibrary.com]

TABLA 11 Resultados de la prueba estadística de rendimientos ajustados al riesgo según la prueba no paramétrica de Friedman con la prueba post-hoc de Hommel

Estrategias comerciales	rango promedio	AjustarpHommel
C+RegyGP (c)	3.0857	.
C+Factor2	5.3143	0.0371
C+FactorM	5.4286	0.0371
p+FactorM	6.4857	0.0044
Factor2	6.7714	0.0023
p+RegyGP	7.2857	4.2690E-4
p+Factor2	7.3143	3.8193E-5
RegyGP	8.5143	2.6705E-6
DCC+FactorM	8.6286	1.5260E-6
DCC+Factor2	8.8571	6.0421E-7
DCC+RegyGP	9.3143	5.6671E-8
RSI	9.6000	1.2147Ey8
FactorM	10.0571	8.3711Ey10
EMA	10.9000	3.4833E-12
MACD	12.4429	2.9136Ey17

Nota: intervalo de 10 minutos fuera de la fecha de la muestra. Diferencias significativas entre el algoritmo de control (indicado con (c) y el los algoritmos representados por una fila al nivel de % se muestran en negrita, lo que indica que el valor de p ajustado es inferior a 0,05.

conocido punto de referencia de compra y retención (BandH), y en la siguiente sección, veremos un muestra de los mejores modelos GP. Bajo BandH, compramos el primer día del primer mes y vendemos el el último día del décimo mes.

La Tabla 12 compara los rendimientos medios de C+RegyGP y la estrategia BandH. C+RegyGP supera a BandH en 12 pares de divisas con un rendimiento promedio general de 0.225% contra un rentabilidad media negativa de -0,128 % en BandH. Además, la varianza de C+RegyGP es 0.153 y BandH es 0.515. Esto indica que C+RegyGP no solo es más rentable, sino también menos arriesgado que BandH. Estos resultados también fueron confirmados por una prueba estadística de Komolorov-Smirnov con un valor de p de 7.2529ey04.

5.2.3 | C+RegyGP: Distribución de rendimientos

Para comprender mejor el rendimiento de C+RegyGP, también analizamos sus rendimientos en más detalle. La figura 7A presenta la distribución de los rendimientos en 50 carreras de GP individuales para los 20 pares de divisas y los cinco umbrales diferentes. Nuestro objetivo está aquí para obtener información sobre el general rendimiento del algoritmo en todos los conjuntos de datos. También hemos ajustado el reparto de devoluciones con una distribución t de Student generalizada, para dar cabida a los valores extremos que la normal la distribución no puede. También se debe tener en cuenta que no trazamos los casos que el algoritmo optó por no comerciar, ya que estos casos no arrojaron ningún rendimiento. Como podemos observar en la figura,

TABLA 12 % Comparación de C+REG-GP y comprar y mantener en términos de rendimiento promedio

Estrategias comerciales	C+RegyGP	Comprar y retener
USD/JPY	0.000	¥6.278
USD/NZD	0.260	¥0,516
AUD/USD	0.273	¥5.728
USD/JPY	0.000	¥4.109
EUR/USD	0.186	¥2.672
USD/USD	0.192	18.555
USD/CSK	0.034	7.770
EUR/GBP	0.104	¥0,292
EUR/JPY	0.020	¥6.211
USD/NOK	0.351	2.046
EUR/USD	¥0.001	8.801
GBP/EUR	0.354	3.936
EUR/CHF	0.202	¥2.395
GBP/USD	¥0.059	8.464
NZD/USD	0.280	¥6.443
diversas estrategias comerciales	0.044	2.345
USD/JPY	0.000	¥9.430
USD/NOK	0.461	¥6.102
USD/EUR	0.030	0.207
EUR/ZAR	1.762	¥4.505
Significar	0.225	¥0,128

Nota: El mejor valor (el más alto) para cada fila (par de divisas) se muestra en negrita.

la media de los rendimientos es positiva (0,3224); la mediana también es positiva en 0.1606. Los retornos tienen sesgo positivo, con un valor de 1,9249. También hay una curtosis significativamente alta de 11.7598, lo que indica que produce más valores atípicos que la distribución normal. El rango de los retornos es [¥3.1413, 7.1294] y la desviación estándar es 0.9628. Además, desde los datos de distribución, hemos generado la CDF empírica de los rendimientos en la Figura 7B, y como podemos observar, el algoritmo logra rendimientos positivos con una probabilidad de alrededor del 65%.

Para obtener más información sobre el rendimiento del algoritmo para cada par de divisas, también presentar la distribución de rendimientos para cada par en la Figura 8. El algoritmo comercial no recomendar cualquier negociación en todas las 50 ejecuciones de GP para AUD/JPY, CAD/JPY y USD/JPY, por lo tanto, estas parcelas están vacías. Esto, en nuestra opinión, es un resultado importante, ya que C+RegyGP es capaz identificar casos que van a ser extremadamente perjudiciales en términos de rentabilidad y, por lo tanto, recomendamos esperar y no tomar ninguna acción en absoluto. También es muy interesante que el algoritmo fue capaz de hacer esto consistentemente para las 50 carreras de GP para los tres mencionados anteriormente pares de divisas Para los conjuntos de datos restantes, C+RegyGP está dando resultados positivos en general. devoluciones. Estamos presentando la media, SD, asimetría y curtosis para cada par de divisas en

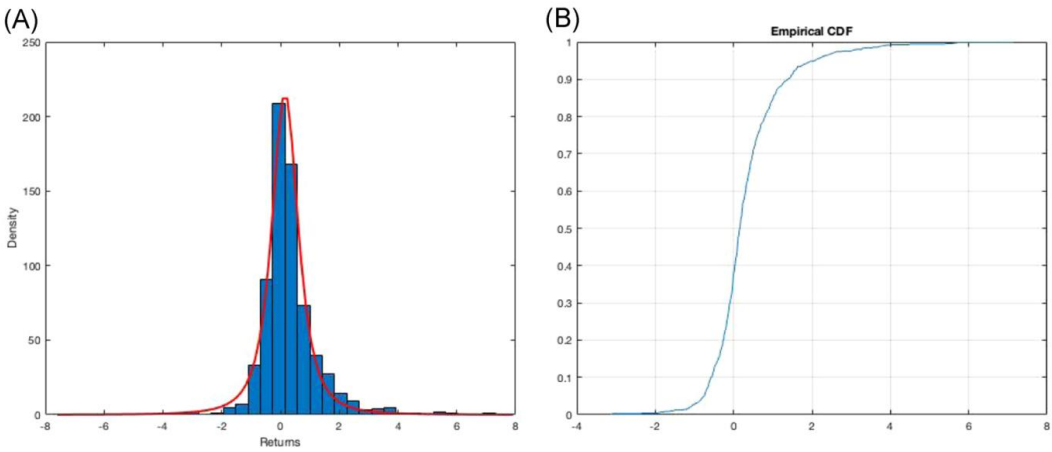


FIGURA 7 (A) Distribución de rendimientos para el algoritmo C+RegyGP en 50 ejecuciones de GP, 20 pares de divisas y cinco umbrales de CC diferentes. La distribución se ha ajustado con una distribución t de Student generalizada. (B) empírico CDF para los rendimientos del algoritmo C+RegyGP en 50 ejecuciones de GP, 20 pares de divisas y cinco umbrales de DC diferentes. DC, cambio direccional; GP, programación genética [La figura en color se puede ver en wileyonlinelibrary.com]

Tabla 13. Con la excepción de EUR/USD y GBP/USD, todos los demás pares están experimentando rendimientos medios positivos. Además, los rendimientos son principalmente sesgados positivamente, con la excepción de EUR/GBP, EUR/USD y USD/NOK. Por último, la curtosis para la mayoría de los pares de divisas es de alrededor de 3, lo que indica que las colas de la distribución experimentan valores atípicos extremos a la par con la distribución normal. En general, consideramos que estos son resultados bastante positivos, ya que demostrar que C+Reg-GP tiene un alto potencial de rendimiento positivo en una variedad de conjuntos de datos.

5.2.4 | Una muestra de los mejores modelos de GP

Para completar, presentamos una muestra de los mejores árboles (en términos de rentabilidad) que C+Regy GP evolucionó en su formato de ecuación. OSI es la longitud de OS y DCI es la longitud de DC.

$$\text{rendimiento} = \text{registro} + \left(\frac{\text{un CC} \cdot I^b}{a} \right) \quad (8)$$

donde $a = 1609.55$ y $b = 5.023$.

$$\text{rendimiento} = \log((x))^{CC} \cdot a = \frac{b}{a} \quad (9)$$

donde $a = 4.117$ y $b = 5.764$.

$$\text{rendimiento} = \cos(x) \cdot \cos(y) + \frac{CC}{\exp(CD(\cos(y)))} \cdot \frac{b}{a} \quad (10)$$

donde $a = 292.160$ y $b = 4.569$

$$\text{rendimiento} = \frac{1}{\exp(\exp(\sin(\sin(x))))} + (x + \frac{b}{a})^{CC} \quad (11)$$

donde $a = 1.750$ y $b = 1.957$.

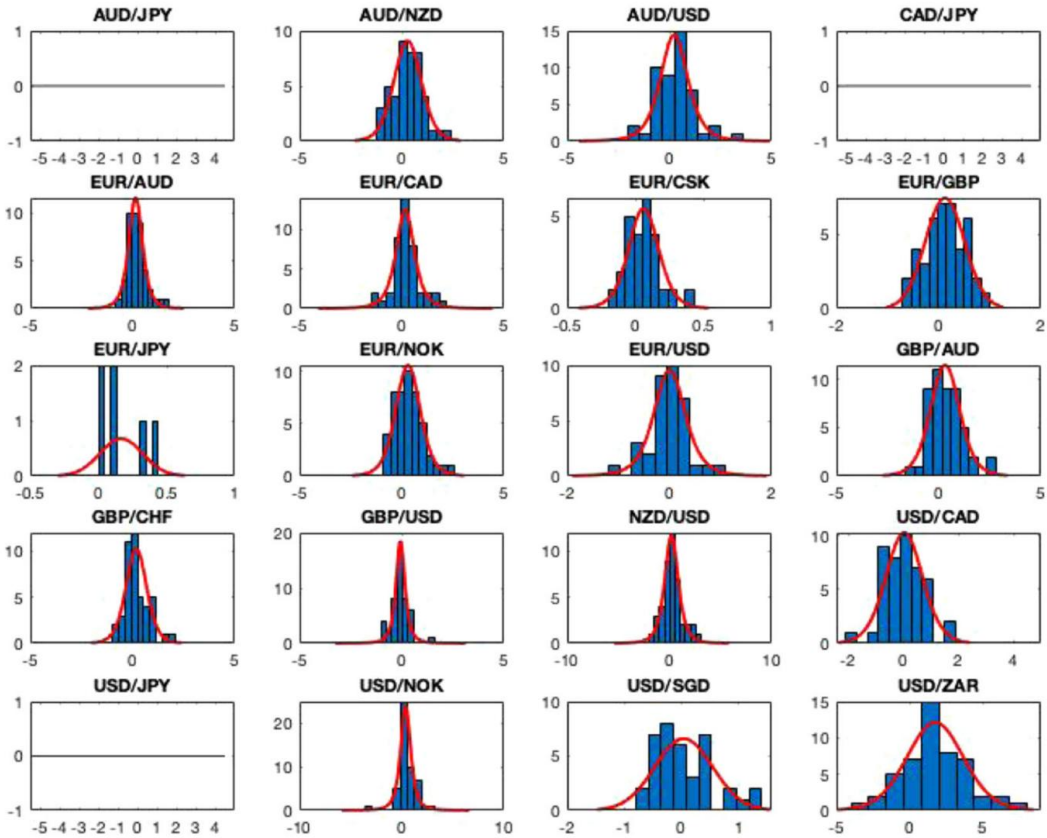


FIGURA 8 Distribución de retornos para el algoritmo C+RegyGP. Los rendimientos se presentan por separado para cada par de divisas y superan las 50 ejecuciones de GP y cinco umbrales de DC. Todas las distribuciones se han ajustado con una distribución t de Student generalizada. El algoritmo de negociación no recomendó ninguna negociación para AUD/JPY, CAD/JPY y USD/JPY, por lo que sus respectivos gráficos están vacíos. DC, cambio direccional; GP, programación genética [La figura en color se puede ver en wileyonlinelibrary.com]

La mayoría de las ecuaciones tienen estructuras diferentes. La primera y la segunda ecuación utilizan la función logarítmica, la tercera consiste en el coseno y la función exponencial, y la cuarta ecuación tiene tres componentes, a saber, el exponencial, el seno y el logaritmo. Lo que podemos concluir de estas ecuaciones para la relación de longitud de DC y OS es que (i) no es lineal y (ii) depende del conjunto de datos. Esta última es una observación importante, ya que indica que debemos desarrollar ecuaciones personalizadas para diferentes conjuntos de datos para comprender la relación DC-OS y, por lo tanto, predecir la inversión de la tendencia.

5.2.5 | Tiempos computacionales

La Tabla 14 presenta los tiempos computacionales promedio para todos los algoritmos. Podemos observar que diferentes algoritmos pueden tener tiempos computacionales significativamente diferentes, lo cual no es sorprendente. Un algoritmo como C+RegyGP incluye el paso de clasificación, que consistió en la ejecución de AutojWEKA durante 60 minutos para encontrar el mejor modelo de clasificación por conjunto de datos, y también

TABLA 13 Estadísticas resumidas para todos los resultados de pares de divisas para el algoritmo C+RegyGP

Divisa par	AUD/ Guay	AUD/ NZD	AUD/ <small>Dólar estadounidense</small>	CANALLA/ Guay	EUR/ AUD	EUR/ CANALLA	EUR/ CSK	EUR/ GBP	EUR/ Guay	EUR/ <small>no está bien</small>
Significar	NaN 0,3		0.29	NaN 0,23		0.23	0.07	0,13 0,17		0.37
Pararse. desarrollo	NaN 0,76		0,97 NaN 0,49			0.7	0.14	0,39 0,18		0.73
Asimetría	NaN 0.25		0.75	NaN 1.14		0.36	0.6	ÿ0,02 0,6		0.86
curtosis	NaN 3.33		4.93	NaN 4,71		3.7	3.67	2,28 1,88		3.84
Divisa par	EUR/USD	GBP/ AUD	GBP/ <small>francos suizos</small>	GBP/ <small>Dólar estadounidense</small>	NZD/ <small>Dólar estadounidense</small>	<small>Dólar estadounidense</small> CANALLA	<small>Dólar estadounidense</small> Guay	<small>Dólar estadounidense</small> no está bien	<small>Dólar estadounidense</small> USD	<small>Dólar estadounidense</small> ZAR
Significar	ÿ0,0009	0.37	0.23	ÿ0,06 0,33		0,06 NaN		0,47 0,04		1.77
Pararse. desarrollo	0.42	0.85	0.61	0,42 1,0		0,73 NaN		0,92 0,52		2.08
Oblicuidad	ÿ0,21	0.62	0.75	0,93 0,71		0,17 NaN	ÿ0,45 0,79			0.17
curtosis	4.09	3.73	3.75	7,11 3,68		3,34 NaN		7.7	2.96	3.17

Nota: El algoritmo de negociación no recomendó ninguna negociación para AUD/JPY, CAD/JPY y USD/JPY, por lo tanto, para estas monedas pares se muestra un valor de NaN en sus respectivas estadísticas.

TABLA 14 Tiempos computacionales promedio por corrida para C+RegyGP, RegyGP, p+RegyGP, DCC+RegyGP, C +Factor-M, Factor-M, p+Factor-M, DCC+Factor-M, O+Reg-GP, Factor-2, p+Factor-2, DCC+Factor-2, RSI, EMA y MACD

Estrategias comerciales	C+RegyGP	RegyGP	p+RegyGP	DCC+RegyGP
Clasificación	~65 minutos — —			
Estimacion	~5,45 minutos	~6,20 minutos	~5,25 minutos	—
Comercio	~3 s	~3 s	~3 s	~3 s
Estrategias comerciales	C+FactorÿM	FactorÿM	p+FactorÿM	DCC+FactorÿM
Clasificación	~65 minutos — —			
Estimacion	~30 s	~30 s	~30 s	—
Comercio	~3 s	~3 s	~3 s	~3 s
Estrategias comerciales	C+Factorÿ2	Factorÿ2	p+Factorÿ2	DCC+Factorÿ2
Clasificación	~65 minutos — —			
Estimacion	~20 s	~20 s	~20 s	—
Comercio	~3 s	~3 s	~3 s	~3 s
Estrategias comerciales	EMA	MACD	RSI	—
Clasificación	—	—		
Estimacion	—	—		
Comercio	~3 s	~3 s	~3 s	~3 s

Nota: BH tarda menos de 1 s en ejecutarse porque compramos moneda cotizada al comienzo del período de negociación y vendemos moneda cotizada en el final del período de negociación.

optimizar sus hiperparámetros;* también incluye un GP, que requiere algún tiempo para desarrollar una buena solución, ya que están involucradas múltiples personas y generaciones.

Para aclarar las cosas, presentamos los tiempos computacionales para cada tarea en nuestro marco: clasificación, estimación (longitud del sistema operativo) y comercio. No todos los algoritmos usan el paso de clasificación, pero los que lo usan necesitan alrededor de 65 minutos para completar esta tarea. La tarea de estimación es de 5 a 6 min para los algoritmos que usan un GP y de 20 a 30 s para los otros algoritmos.

Con respecto al paso comercial, todos los algoritmos necesitan alrededor de 3 s.

Cabe señalar que el aprendizaje en el conjunto de entrenamiento generalmente ocurre fuera de línea, por lo que una duración de 65 a 70 minutos no constituye un problema. Una vez que se completa el entrenamiento, el mejor modelo se aplica en tiempo real al conjunto de prueba (no visto), que solo toma 3 s. Creemos que las mejoras significativas que hemos observado en rentabilidad y riesgo justifican el menor tiempo de ejecución. Por último, la sobrecarga de incluir un paso de clasificación se puede reducir al paralelizar el proceso de AutoWeka. De hecho, se ha demostrado en la literatura (p. ej., Referencia [34]) que la paralelización puede reducir significativamente los tiempos de cálculo.

5.3 | Resumen

Nuestros hallazgos se pueden resumir de la siguiente manera:

Agregar un paso de clasificación a un algoritmo DC tiene un efecto positivo en la predicción de la inversión de tendencia bajo cambios direccionales. Como observamos en la Tabla 6, los resultados de clasificación muy positivos han llevado a un RMSE significativamente reducido, clasificando cada algoritmo que usa un clasificador más alto que su respectiva variante sin clasificación. Además, C+GP ocupó el primer lugar y superó estadísticamente a todos los demás algoritmos de inversión de tendencia basados en DC.

La introducción de un paso de clasificación en un algoritmo DC conduce a mayores rendimientos durante la negociación. Como observamos en las Tablas 7 y 8, todos los algoritmos que utilizaron un clasificador (C+Reg-GP, C+Factor-M y C+Factor-2) superaron a otras variantes sin clasificador. Además, C+RegGP ocupó el primer lugar entre 15 algoritmos comerciales y superó estadísticamente a 12 algoritmos, con la única excepción de los otros dos algoritmos que usaban un clasificador.

La introducción de un paso de clasificación en un algoritmo DC conduce a estrategias menos arriesgadas. Como vimos en los resultados de la relación de Sharpe, todas las variantes con el clasificador se clasificaron en los primeros tres lugares (Tabla 11). Esto quizás podría atribuirse al hecho de que el índice de Sharpe es una métrica que incluye tanto la rentabilidad como el riesgo. Por otro lado, los resultados de MDD presentaron una imagen mixta, con C+Reg-GP ocupando el primer lugar en todos los algoritmos, pero Factor-M y Factor-2 ocupando un lugar más alto que sus variantes con un clasificador.

No existe una fórmula generalizada para predecir la inversión de tendencia en los cambios de dirección. Cada El conjunto de datos tiene sus propias características y requiere ecuaciones de inversión de tendencia personalizadas.

C+RegGP es un algoritmo comercial efectivo. No solo superó a otros algoritmos basados en DC, sino también a tres indicadores técnicos diferentes, así como a comprar y mantener. Este fue el caso no solo de los rendimientos promedio, sino también de MDD y Sharpe ratio (métricas de riesgo).

6 | CONCLUSIÓN

Para concluir, este documento presentó una investigación extensa sobre un total de 1000 conjuntos de datos de 20 pares de divisas Forex diferentes para demostrar que la introducción de un paso de clasificación en Resúmenes de precios basados en CD, donde predecimos si un evento de CD va a ser seguido por un

Evento OS, conduce a mejores rendimientos y resultados de riesgo en el comercio. Comparamos nuestros resultados en tres algoritmos DC, donde ejecutamos experimentos para dos versiones por algoritmo, una con un clasificador y otra sin clasificador. También comparamos nuestros resultados con el análisis técnico y comprar y mantener. Nuestros resultados confirmaron que el uso de la clasificación conduce a una mejor predicción de inversión de tendencia y, por lo tanto, a estrategias comerciales rentables y de bajo riesgo. También encontramos que uno de los algoritmos de DC (C+GP+TS) supera constantemente a todos los demás algoritmos en todas las métricas que tuvieron lugar en nuestra investigación.

Como trabajo futuro, nos gustaría crear estrategias comerciales de DC multiumbral. En esas estrategias, todos los umbrales contribuirán al proceso de toma de decisiones para realizar acciones comerciales. Esto tendría la ventaja de combinar el "conocimiento" de múltiples umbrales, lo que podría superar el rendimiento de las estrategias comerciales de umbrales individuales. Se podrían realizar investigaciones adicionales para crear algoritmos de clasificación personalizados, en lugar de usar AutoWeka.

CONFLICTO DE INTERESES Los autores declaran que no existen conflictos de intereses.

CONTRIBUCIONES DE LOS AUTORES

Adesola Adegboye: Software; validación; análisis formal; investigación; escritura – borrador original; escritura – revisión y edición, visualización. Michael Kampouridis: Conceptualización; metodología; validación; escritura – revisión y edición; supervisión; administración de proyecto.

Fernando Otero: Conceptualización; metodología; validación; escritura – revisión y edición; supervisión.

NOTAS FINALES

*Un valor negativo representa un retorno negativo; un valor entre 0,2 y 0,3 está en línea con el mercado general; un valor entre 0,5 y 1 representa un rendimiento superior al mercado; un valor superior a 1 representa un rendimiento excelente.

† El tiempo empleado en la fase de clasificación de C+RegGP, C+FactorM y C+Factor2 superó el tiempo asignado de 60 min debido a la división del tiempo de la CPU, ya que otros procesos se estaban ejecutando en el hardware simultáneamente. Con la disponibilidad de hardware dedicado con suficientes núcleos de CPU, se podría obtener una gran aceleración cambiando la fase de clasificación del modo en serie al modo paralelo y también reduciendo el tiempo de ejecución. Por ejemplo, usar hardware de 60 núcleos y reducir el tiempo de ejecución a alrededor de 2 min.

ORCID

Adesola Adegboye <https://orcid.org/0000-0002-4698-8849> Michael

Kampouridis <https://orcid.org/0000-0003-0047-7565> Fernando Otero <https://orcid.org/0000-0003-2172-297X>

REFERENCIAS

1. Brabazon A, Kampouridis M, O'Neill M. Aplicaciones de la programación genética a las finanzas y la economía: pasado presente Futuro. *Mach evolutivo del programa genético*. 2020;21:33y53.
2. Mandelbrot B, Taylor HM. Sobre la distribución de las diferencias de precio de las acciones. *Operaciones Res*. 1967; 15 (6): 1057y1062.
3. Cavalcante RC, Brasileiro RC, Souza VL, Nobrega JP, Oliveira AL. inteligencia computacional y financiera mercados: una encuesta y direcciones futuras. *Aplicación de sistema experto* 2016;55:194y211.

4. Wan Y, Gong X, Si YW. Efecto de la segmentación en la coincidencia de patrones de series temporales financieras. *Computación suave de la aplicación*. 2016;38:346-359.
5. Chen T, Chen F. Un modelo de reconocimiento de patrones inteligente para respaldar las decisiones de inversión en acciones mercado. *Informar a la ciencia*. 2016;346:261-274.
6. Chung FL, Fu TC, Luk R, Ng V. Coincidencia de patrones de series temporales flexibles basada en puntos perceptivamente importantes. En la Conferencia Internacional Conjunta sobre Taller de Inteligencia Artificial sobre el Aprendizaje a partir de Datos Temporales y Espaciales; 2000:1-7.
7. Yin J, Si YW, Gong Z. Segmentación de series de tiempo financieras basadas en puntos de inflexión. En *Actas 2011 Congreso Internacional de Ciencia e Ingeniería de Sistemas*. IEEE;2011:394-399.
8. Azzini A, da Costa Pereira C, Tettamanzi AG. Modelado de puntos de inflexión en los mercados financieros con técnicas de soft computing. En *Computación Natural en Finanzas Computacionales*. Saltador; 2010:147-167.
9. Özorhan MO, Toroslu YH, Yehitoğlu OT. Predicción de tendencias a corto plazo en datos de series temporales financieras. *Sistema de información Knowl*. 2018:1-33.
10. Glattfelder J, Dupuis A, Olsen R. Patrones en datos de efectos de alta frecuencia: descubrimiento de 12 escalas empíricas leyes Finanzas cuantitativas. 2011;11(4):599-614.
11. Tsang EP, Tao R, Sergueeva A, Ma S. Perfilando movimientos de precios de acciones de alta frecuencia en cambios direccionales. *Finanzas cuantitativas*. 2017;17(2):217-225.
12. Adegboye A, Kampouridis M, Johnson CG. Programación genética de regresión para estimar el final de tendencia en el mercado de divisas. En *IEEE Symposium Series on IEEE Computational Intelligence (SSCI)*;2017:1-8.
13. Sewell M. Caracterización de series temporales financieras. Nota de Investigación RN/11/01. Departamento de Ciencias de la Computación de la UCL, Londres; 2011.
14. Guillaume DM, Dacorogna MM, Davé RR, Müller UA, Olsen RB, Pictet OV. Del ojo de pájaro al microscopio: un estudio de los nuevos hechos estilizados de los mercados de divisas intradiarios. *Stochast Finanzas*. 1997;1(2):95-129.
15. Glattfelder J, Dupuis A, Olsen R. Un extenso conjunto de leyes de escala y el centro de costa de f_x para Com Agentes financieros y económicos putacionales, serie de documentos de trabajo WP025-08; 2008.
16. En voz alta M. Estrategia de negociación de eventos de cambio direccional: estrategia de aprendizaje para maximizar las ganancias. en el séptimo Conferencia Internacional sobre Tecnología y Aplicaciones Cognitivas Avanzadas; 2016.
17. YO en voz alta. Indicadores de análisis de series temporales bajo cambios direccionales: el caso del mercado bursátil saudí. En *t J Econ cuestiones financieras*. 2016;6:1.
18. Tsang E, Chen J. Detección de cambio de régimen utilizando indicadores de cambio direccional en el mercado de divisas mercado para trazar Brexit. *IEEE Trans Emerg Topics Computat Intell*. 2018;2(3):185-193.
19. Chen J, Tsang E. Clasificación de regímenes normales y anormales en los mercados financieros. *Algoritmos*. 2018; 11(12):202.
20. Ao H. Un estudio basado en cambios direccionales en el mercado de valores. Tesis doctoral. Universidad de Essex; 2018.
21. Aloud M, Tsang E, Olsen R. Modelado del comportamiento de los comerciantes del mercado de divisas: un enfoque basado en agentes. En *Banca, Finanzas y Contabilidad: Conceptos, Metodologías, Herramientas y Aplicaciones: Conceptos, Metodologías, Herramientas y Aplicaciones*; 2014:350.
22. Bakhach A, Tsang E, Ng WL, Chinthapathi VR. Agente de reacción: una estrategia comercial basada en el cambio direccional. En *2016 IEEE Symposium Series on Computational Intelligence (SSCI)*. IEEE; 2016:1-9.
23. Bakhach A, Chinthapathi V, Tsang E, El Sayed A. Agente de contragolpe dinámico inteligente: una estrategia comercial basado en el marco de cambio direccional. *Algoritmos*. 2018; 11(11): 171.
24. Kablan A, Ng WL. Comercio intradiario de divisas de alta frecuencia con sistemas de inferencia neuro-difusos adaptativos. *Int J Mercados Financieros Derivados*. 2011;2(1-2):68-87.
25. Gypteau J, Otero FE, Kampouridis M. Generación de estrategias comerciales basadas en cambios direccionales con programación genética. En *Conferencia Europea sobre las Aplicaciones de la Computación Evolutiva*. Saltador; 2015:267-278.
26. Alkhamees N, Fasli M. Una estrategia comercial basada en cambios direccionales con umbrales dinámicos. En *2017 Conferencia internacional IEEE sobre ciencia de datos y análisis avanzado (DSAA)*. IEEE;2017:283-292.
27. Almeida RJ, Baytürk N, Golan R. Estimación del valor en riesgo intradía para eventos de cambio direccional y estrategias de inversión. En *2017 IEEE Symposium Series on Computational Intelligence (SSCI)*. IEEE;2017:1-8.

28. Kampouridis M, Otero FE. Estrategias comerciales en evolución utilizando cambios direccionales. Aplicación de sistema experto 2017;73: 145-160.
29. Kampouridis M, Adegboye A, Johnson C. Evolución de las estrategias comerciales de cambios direccionales con un nuevo indicador basado en eventos. En la Conferencia Asia-Pacífico sobre Evolución y Aprendizaje Simulados. Springer;2017:727-738.
30. Poli R, Langdon WB, McPhee NF, Koza JR. Una guía de campo para la programación genética. Lulu. com. 2008.
31. Thornton C, Hutter F, Hoos HH, Leyton-Brown K. AutoWEKA: selección combinada y optimización de hiperparámetros de algoritmos de clasificación. En Actas de la 19.ª Conferencia Internacional ACM SIGKDD sobre Descubrimiento de Conocimiento y Minería de Datos. ACM; 2013:847-855.
32. Adegboye A, Kampouridis M. Clasificación de aprendizaje automático y modelos de regresión para predecir el cambio de tendencia en los mercados de divisas. Aplicación de sistema experto 2021. (En prensa).
33. López-Ibáñez M, Dubois-Lacoste J, Stützle T, Birattari M. The irace package, iterated race for automatic configuration of the algorithm. Informe técnico, Citeseer; 2011.
34. Brookhouse J, Otero FE, Kampouridis M. Trabajando con OpenCL para acelerar un algoritmo de pronóstico financiero de programación genética: resultados iniciales. En Actas de la publicación complementaria de la Conferencia anual de 2014 sobre computación genética y evolutiva; 2014:1117-1124.

Cómo citar este artículo: Adegboye A, Kampouridis M, Otero F. Mejora de la estimación de inversión de tendencia en los mercados de divisas bajo un paradigma de cambios direccionales con algoritmos de clasificación. Int J Intel Syst. 2021;1-32. <https://doi.org/10.1002/int.22601>